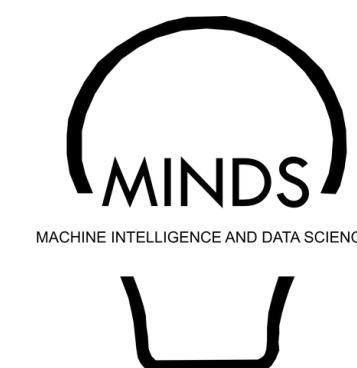


Previsão de Séries Temporais de Evapotranspiração de Referência com Redes Neurais Convolucionais

Patrícia de Oliveira e Lucas

Escola de Engenharia
Universidade Federal de Minas Gerais

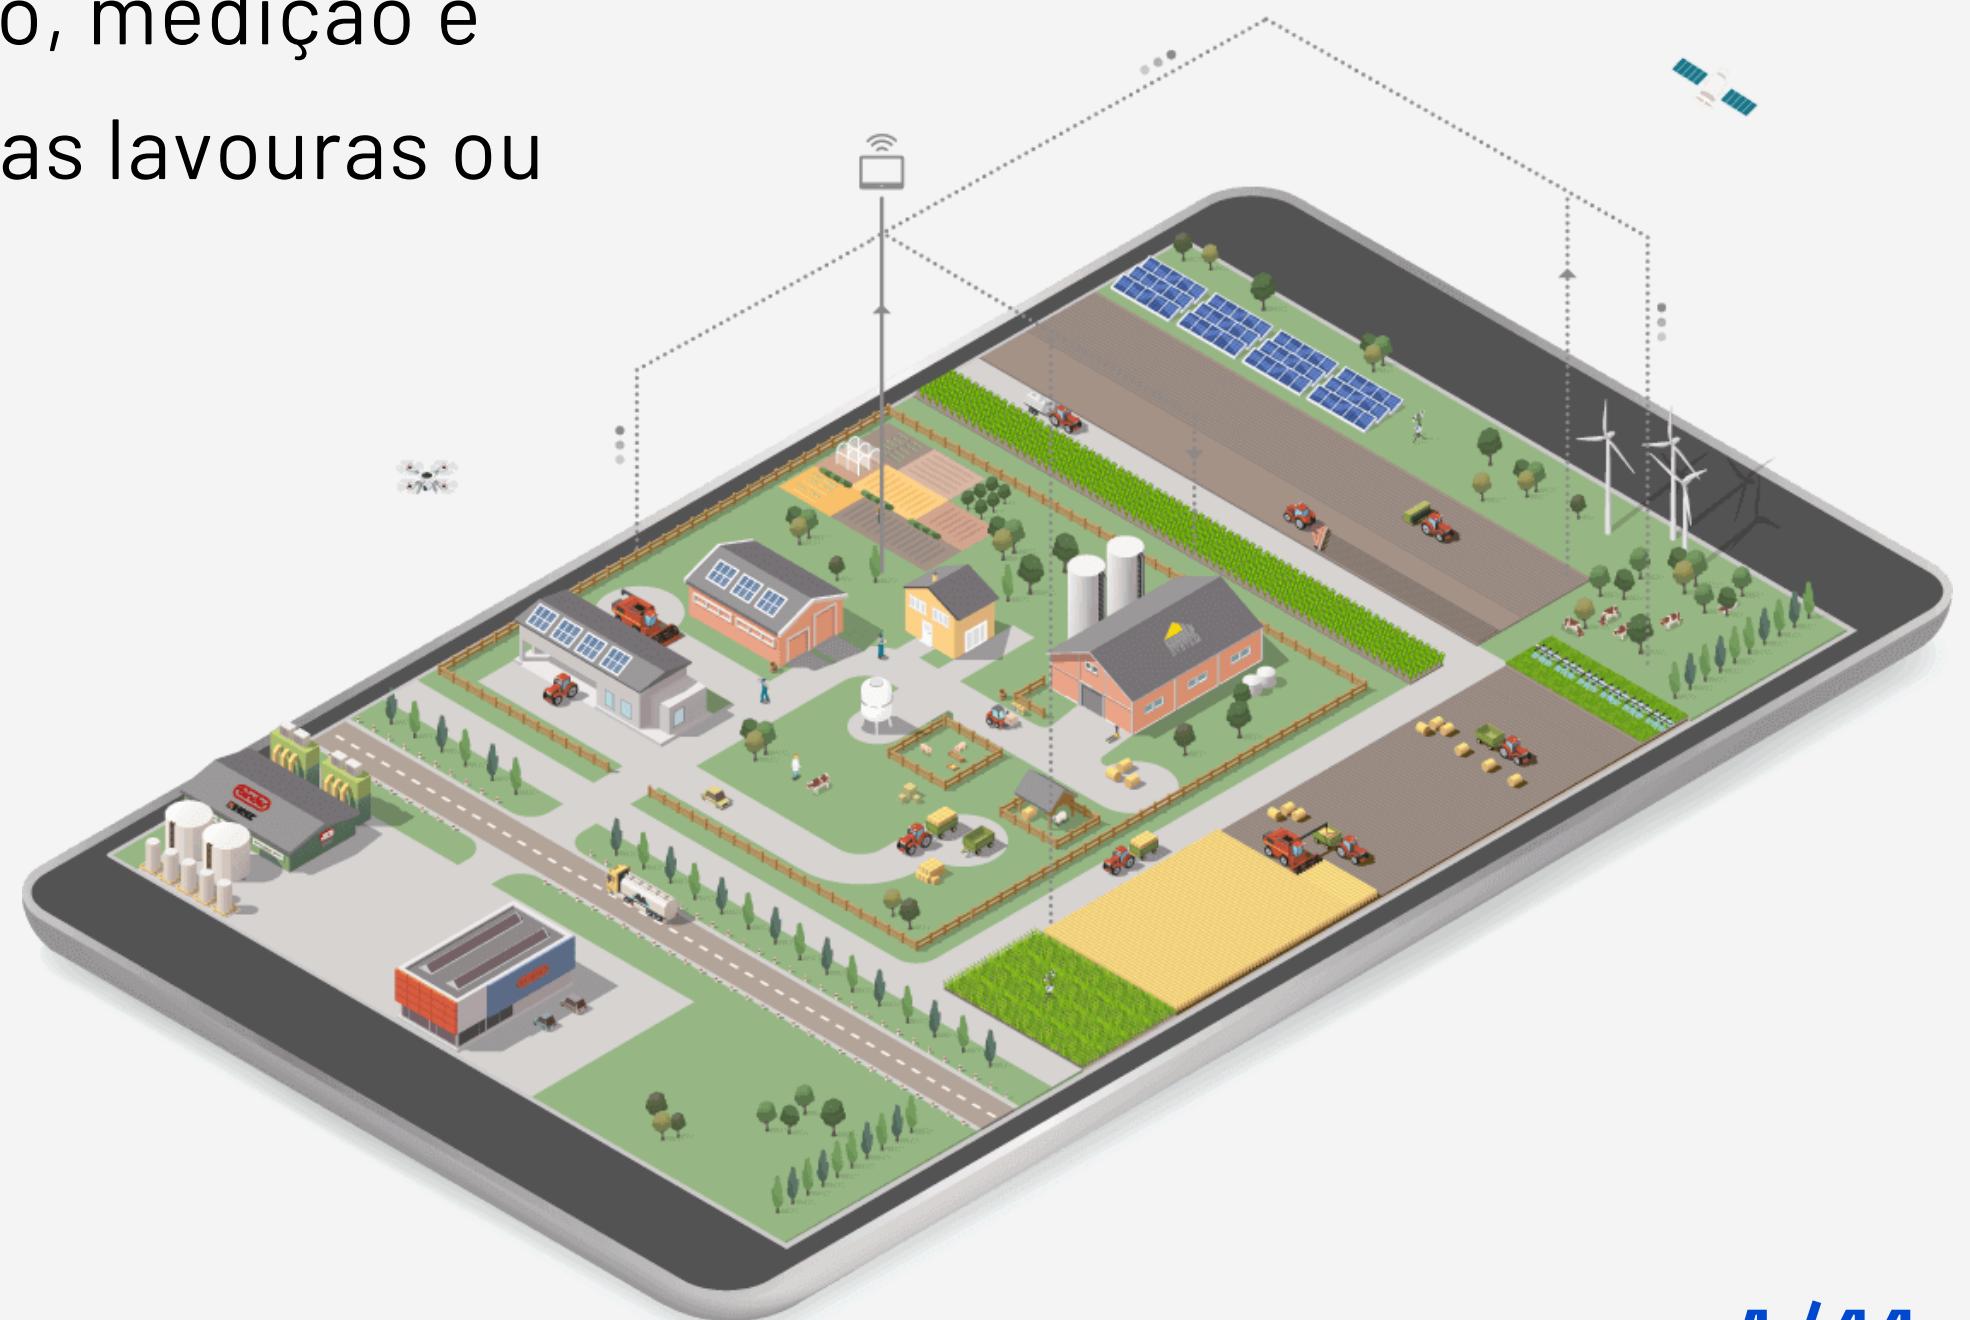
U F *m* G



AGRICULTURA 4.0

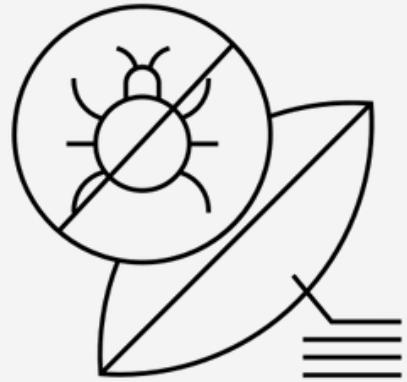
Gestão agrícola baseada na observação, medição e resposta à variabilidade de aspectos das lavouras ou da criação de animais.

Deve ser capaz de fornecer às plantas e animais exatamente o que precisam e quando precisam, aumentando a produtividade e reduzindo os impactos ambientais.

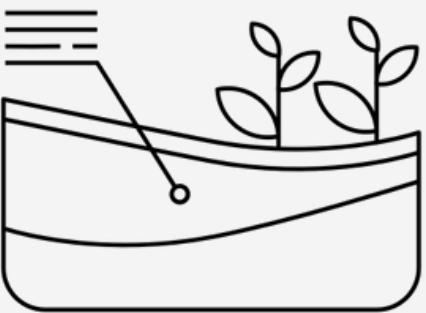


AGRICULTURA 4.0

Gestão das culturas



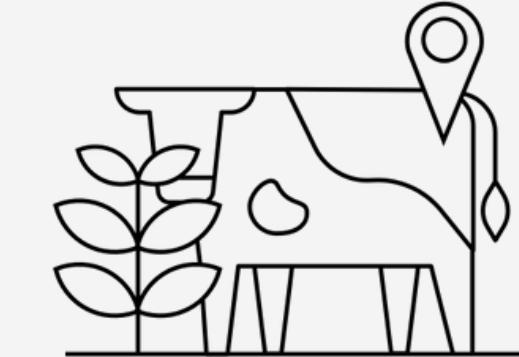
Gestão do solo



Gestão da água



Gestão dos animais



MOTIVAÇÃO

- 1** Por que a gestão eficiente da água é importante para o setor agrícola?
- 2** Como melhorar o desempenho e a sustentabilidade dos sistemas de irrigação?
- 3** Por que prever a Evapotranspiração de Referência?
- 4** Por que usar técnicas de *deep learning* para prever a Evapotranspiração de Referência?

OBJETIVOS

Investigar o uso de modelos de aprendizagem profunda, em especial das redes neurais convolucionais, na previsão de séries temporais de evapotranspiração de referência.

- 1 Buscar, através da pesquisa bibliográfica, conhecimento acerca do processo de evapotranspiração e de modelos de redes neurais convolucionais gerais e específicos para aplicações com dados sequenciais.
- 2 Implementar modelos de redes neurais convolucionais para previsão de séries temporais de evapotranspiração de referência, usando um algoritmo genético como abordagem para a otimização dos hiperparâmetros das redes.
- 3 Realizar experimentos para quantificar a precisão dos modelos de redes neurais convolucionais implementados e compará-los aos modelos ARIMA, WFTS, LSTM.
- 4 Avaliar o desempenho da combinação de modelos de redes neurais convolucionais em modelos ensemble e obter previsões probabilísticas de evapotranspiração de referência.

EVAPOTRANSPIRAÇÃO

A evapotranspiração (ET) é a variável mais ativa do ciclo hidrológico e a principal componente no balanço hídrico em ecossistemas agrícolas.

ET = a quantidade de água evaporada e transpirada por uma superfície com vegetal, durante um determinado período do tempo.

Pode ser expressa como altura equivalente de água evaporada em $mm\ t^{-1}$.

$$ET = E + T$$

Transpiração



Evaporação

EVAPOTRANSPIRAÇÃO

Fatores que afetam a evapotranspiração:



Características
da cultura



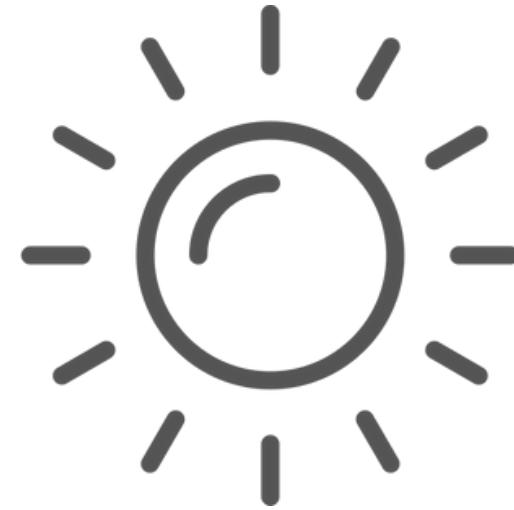
Manejo e os aspectos
ambientais



Parâmetros
climáticos

EVAPOTRANSPIRAÇÃO

Parâmetros climáticos:



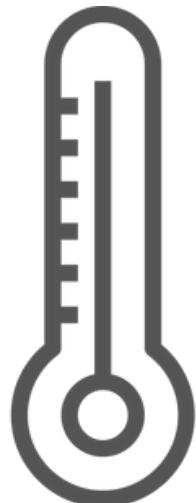
Radiação



Umidade



Velocidade
do vento



Temperatura

EVAPOTRANSPIRAÇÃO DE REFERÊNCIA



Parâmetros
climáticos

+



Superfície de
referência

=

ETo

Evapotranspiração
de referência

A quantidade de água requerida por uma cultura é calculada a partir da evapotranspiração de referência (ETo) e do coeficiente da cultura (Kc).

EVAPOTRANSPIRAÇÃO DE REFERÊNCIA

Equação Penman-Monteith parametrizada de acordo com a superfície de referência:

$$ET_{FAO} = \frac{0.408\Delta(R_n - G) + \gamma \frac{900}{T+273} u_2(e_s - e_a)}{\Delta + \gamma(1 + 0.34u_2)}$$

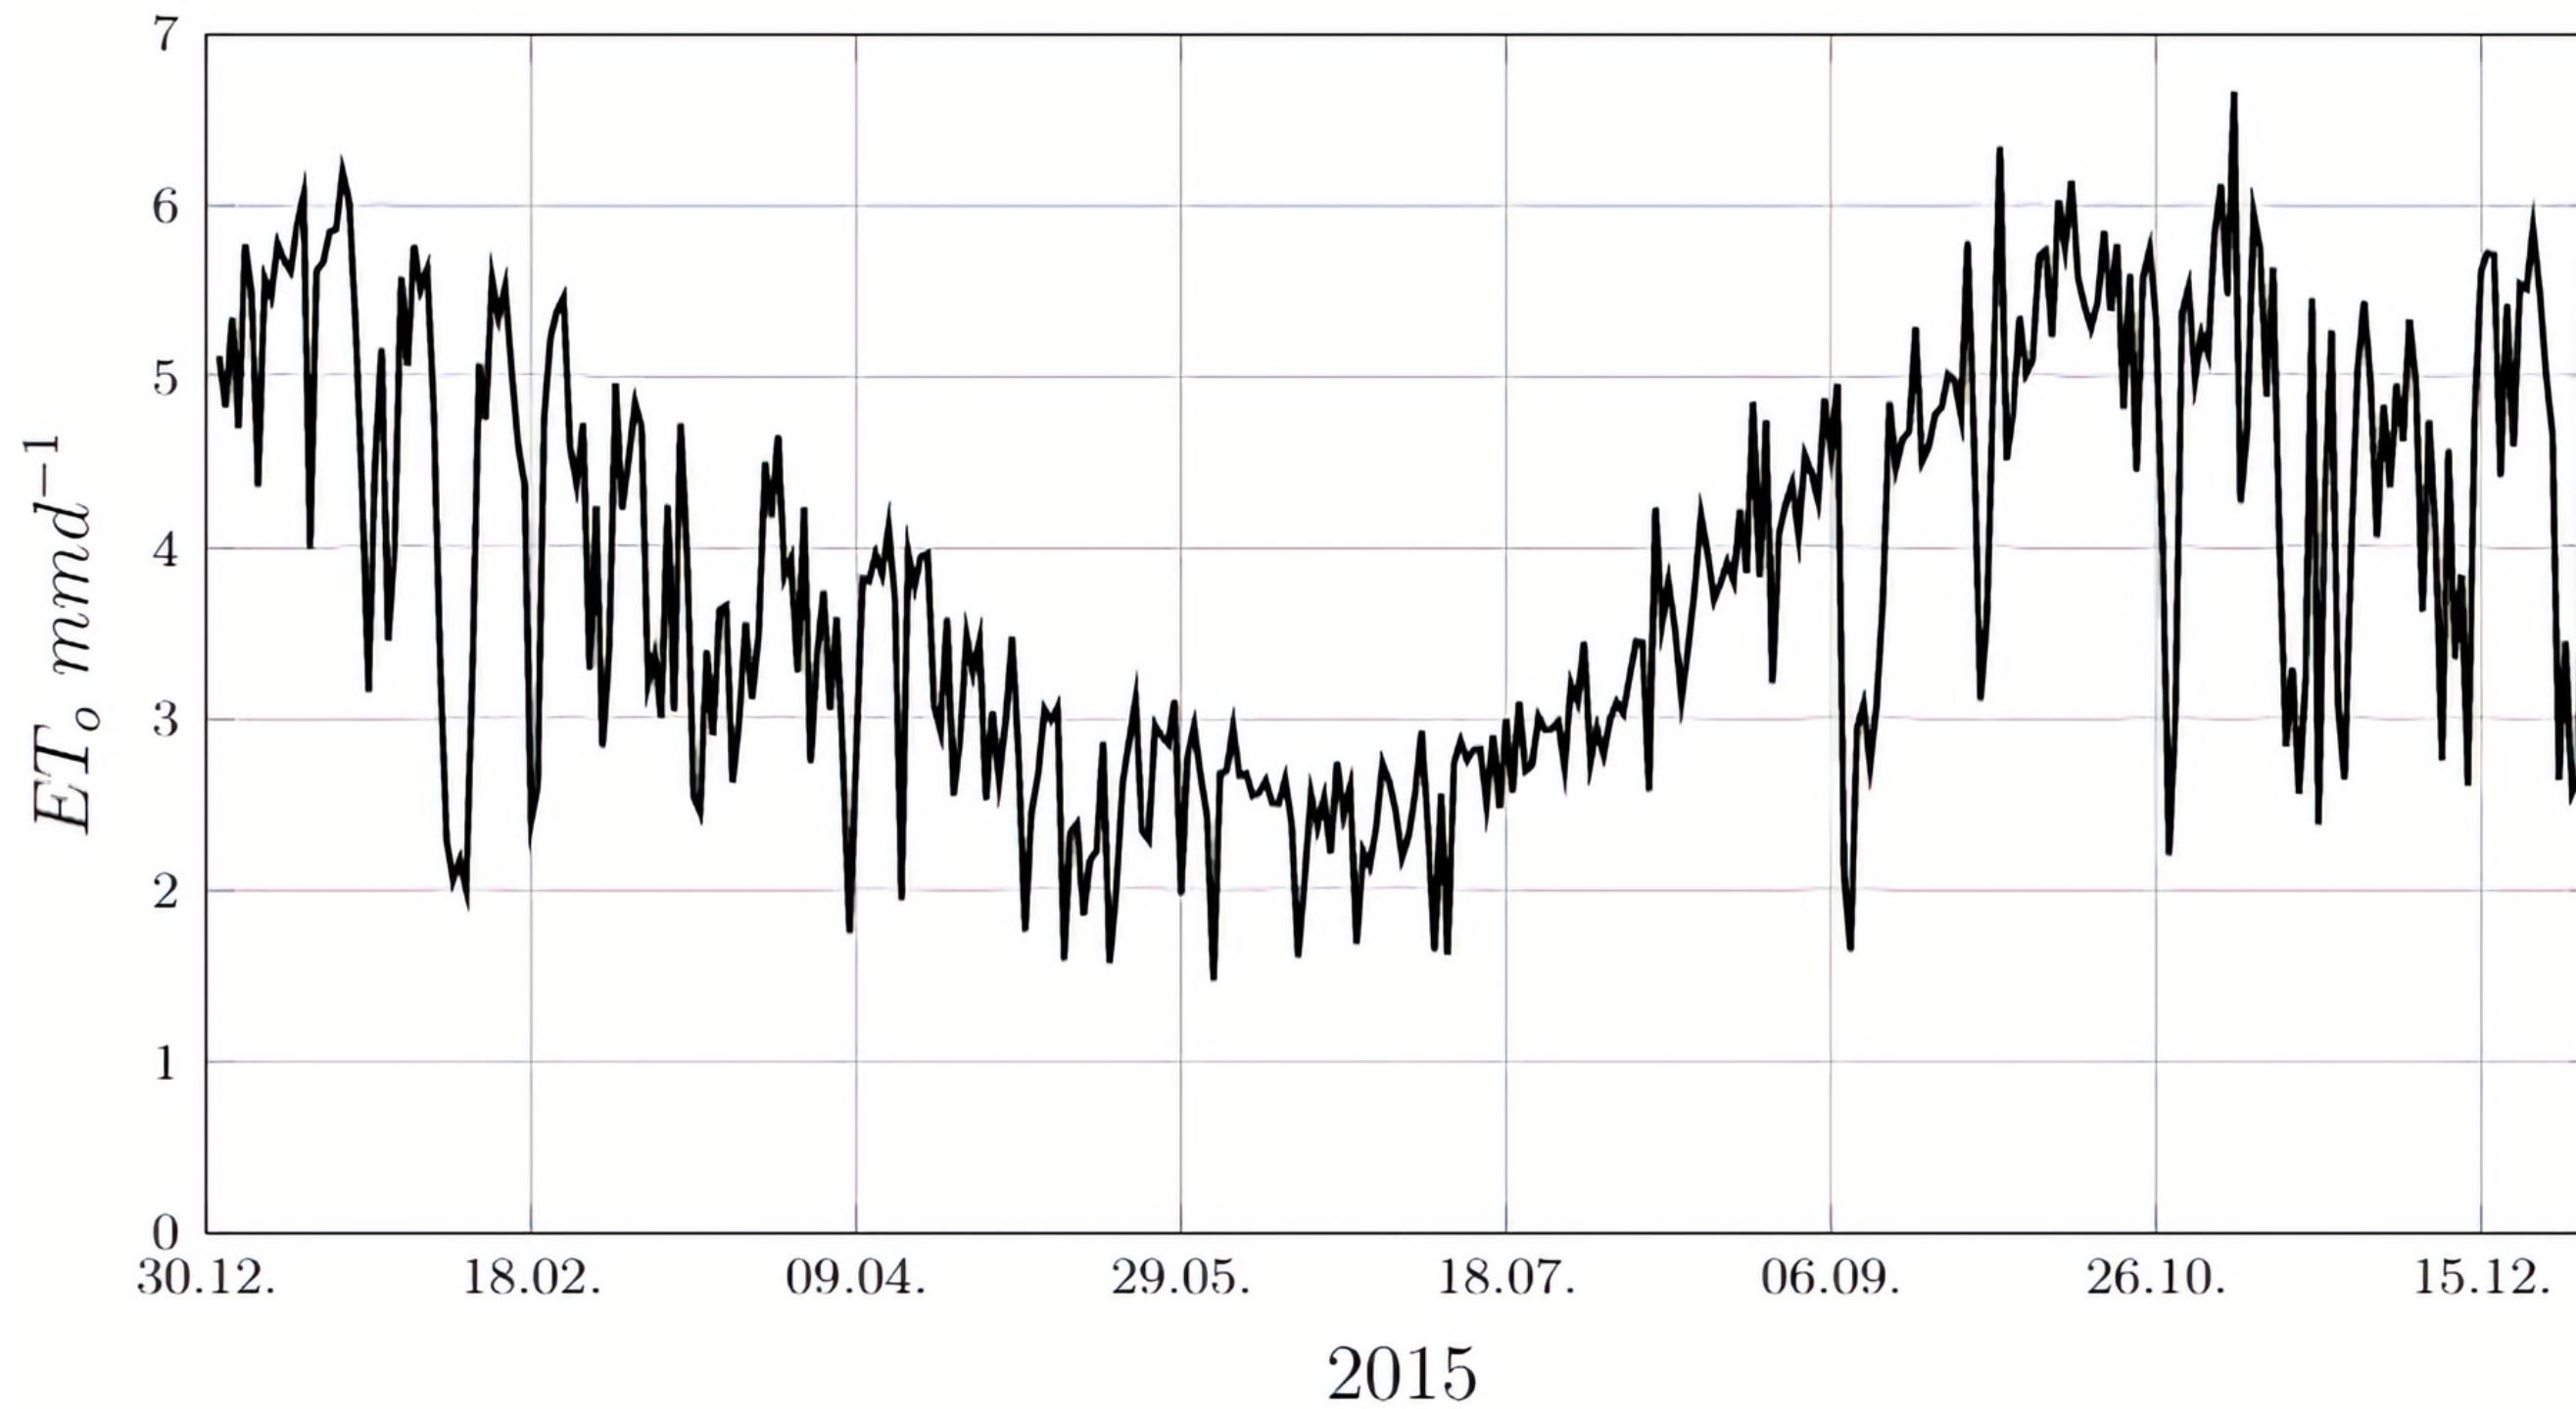
SÉRIE TEMPORAL DE EVAPOTRANSPIRAÇÃO DE REFERÊNCIA

Os dados climáticos utilizados para gerar a série temporal de ETo são originários da estação número 83586 do INMET - Instituto Nacional de Meteorologia, localizada no município de Sete Lagoas, estado de Minas Gerais.

A série histórica registrada nesta estação compreende o período de 1993 a 2015, constituindo 22 anos de dados diários, referentes às seguintes variáveis meteorológicas:

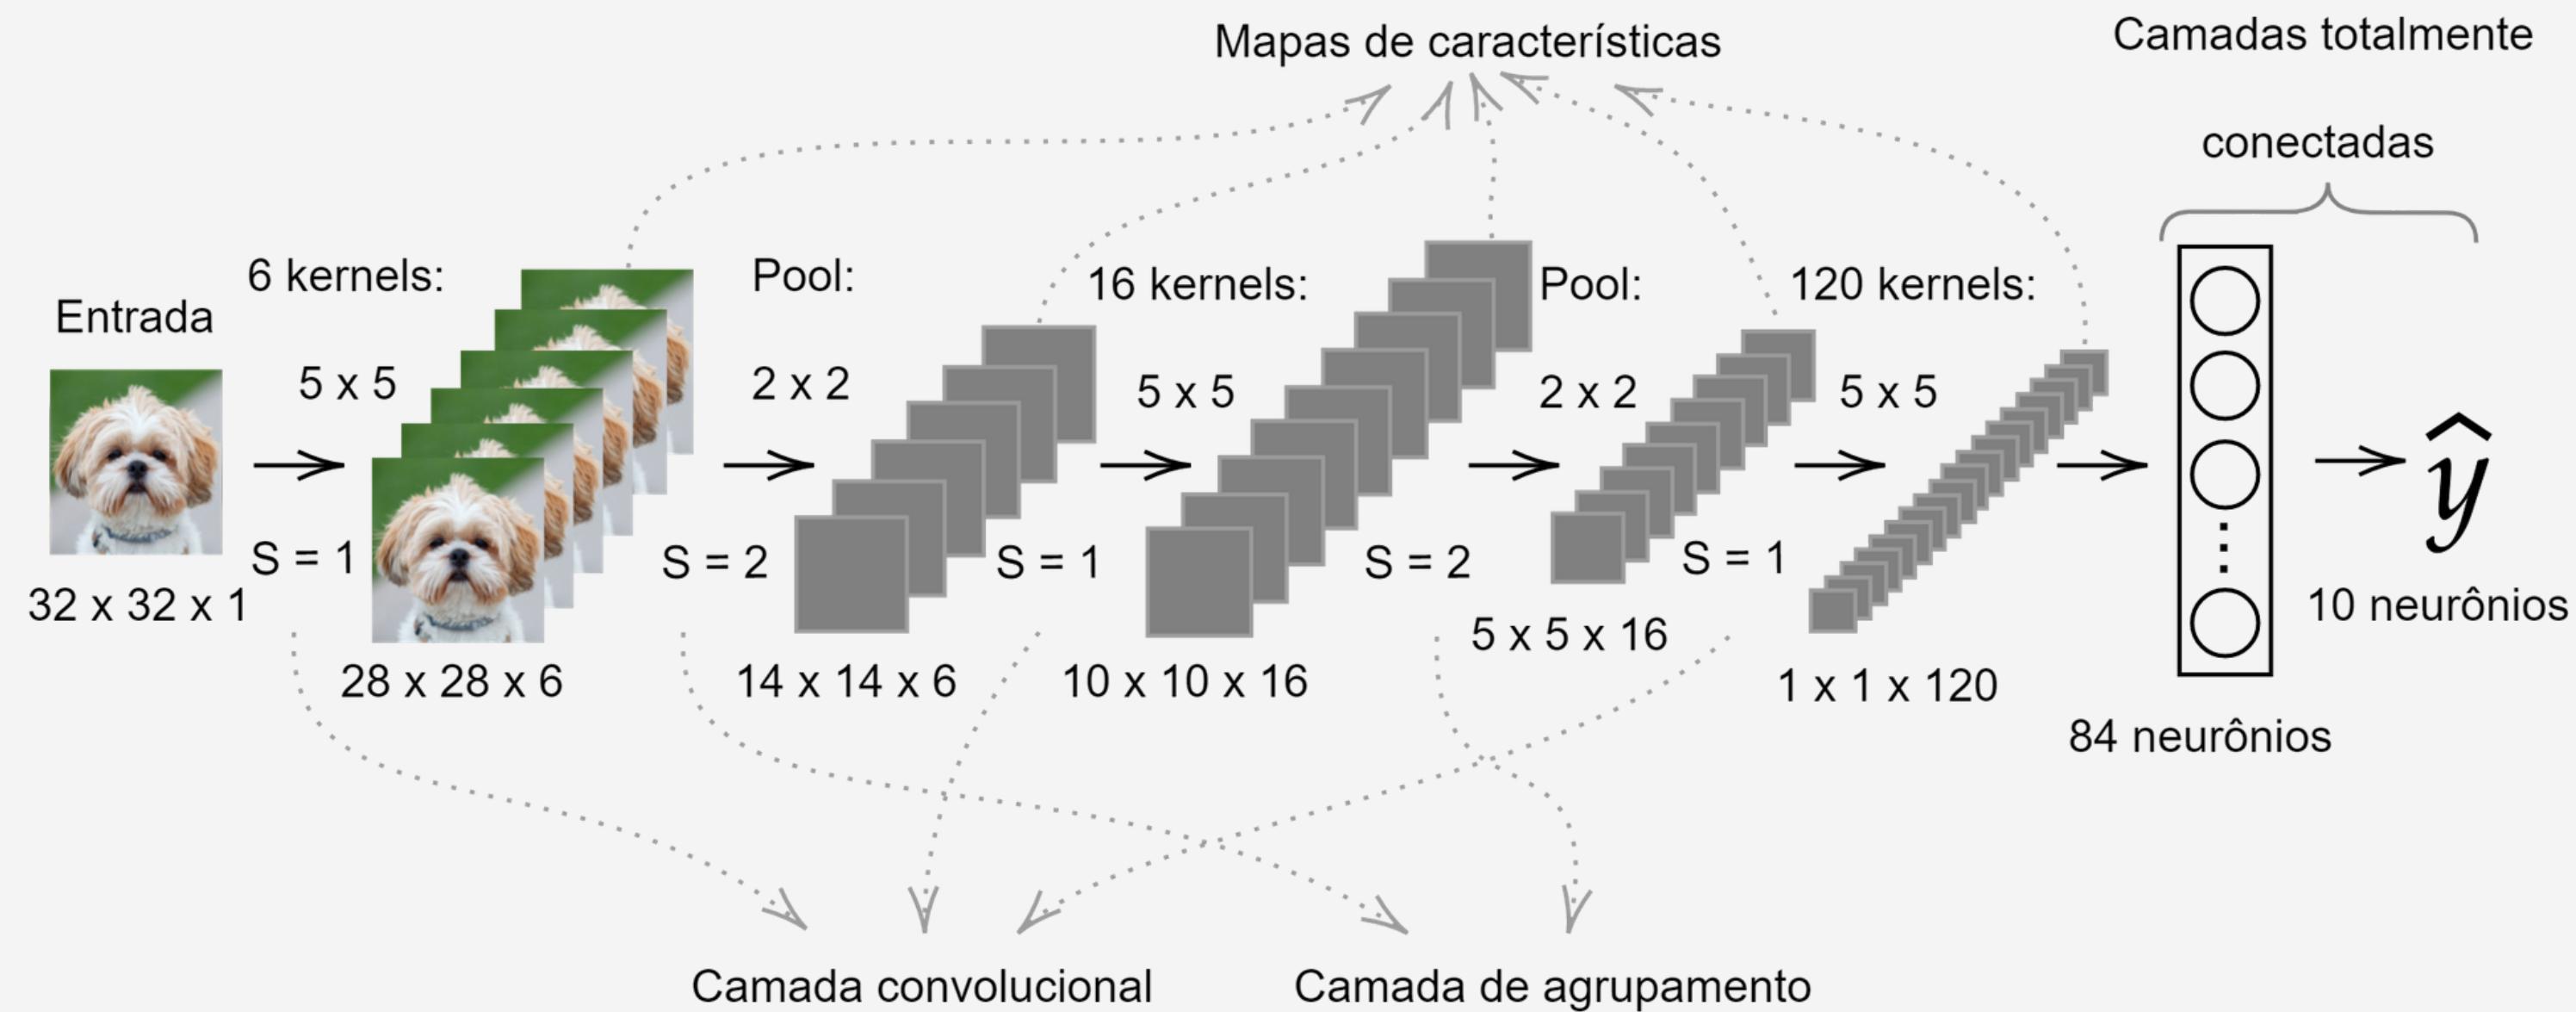
- T_{max} = temperatura máxima [°C];
- T_{min} = temperatura mínima [°C];
- U_2 = velocidade do vento a 2m de altura [ms⁻¹];
- RH= umidade relativa média [%];
- I= insolação [h].

SÉRIE TEMPORAL DE EVAPOTRANSPIRAÇÃO DE REFERÊNCIA



REDES CONVOLUCIONAIS

LeNet-5

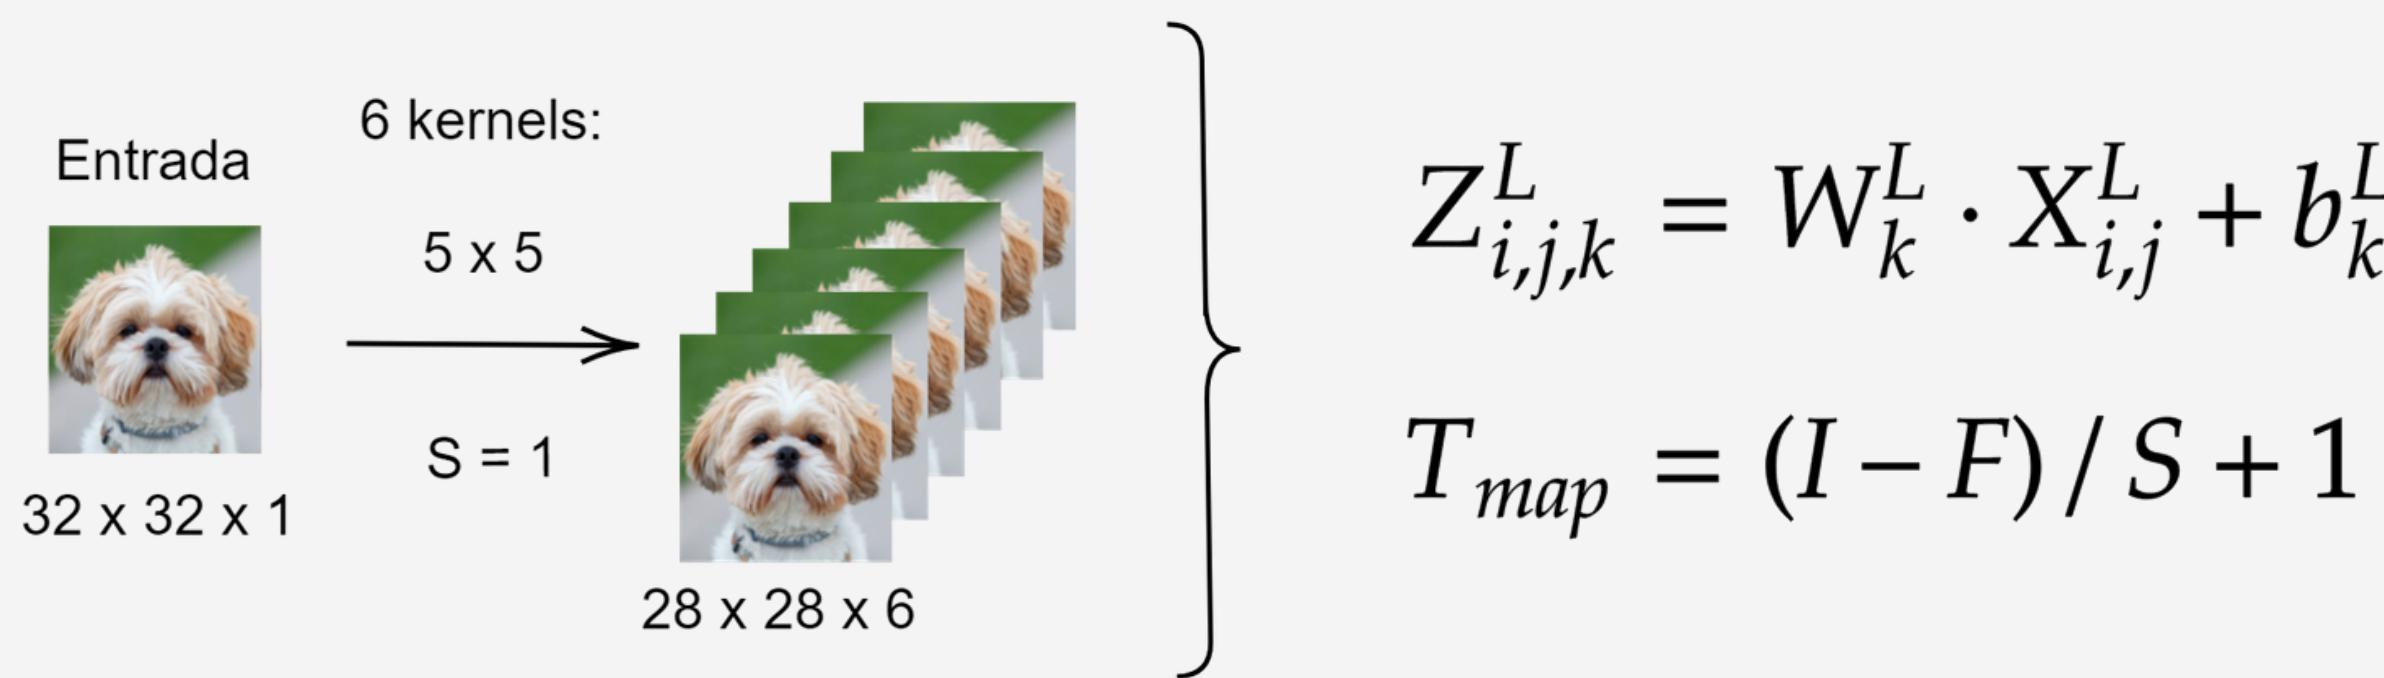


REDES CONVOLUCIONAIS

Camada convolucional

Função: extrair características da entrada.

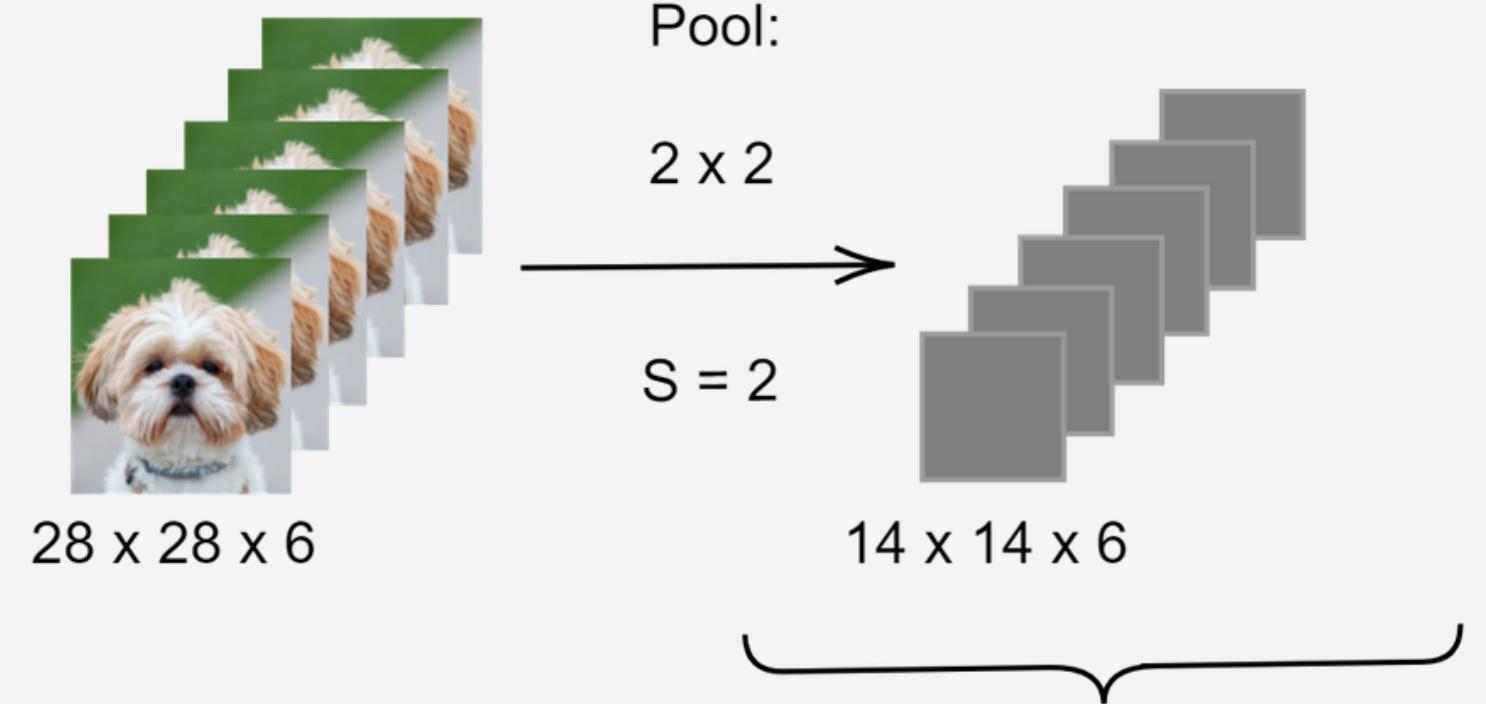
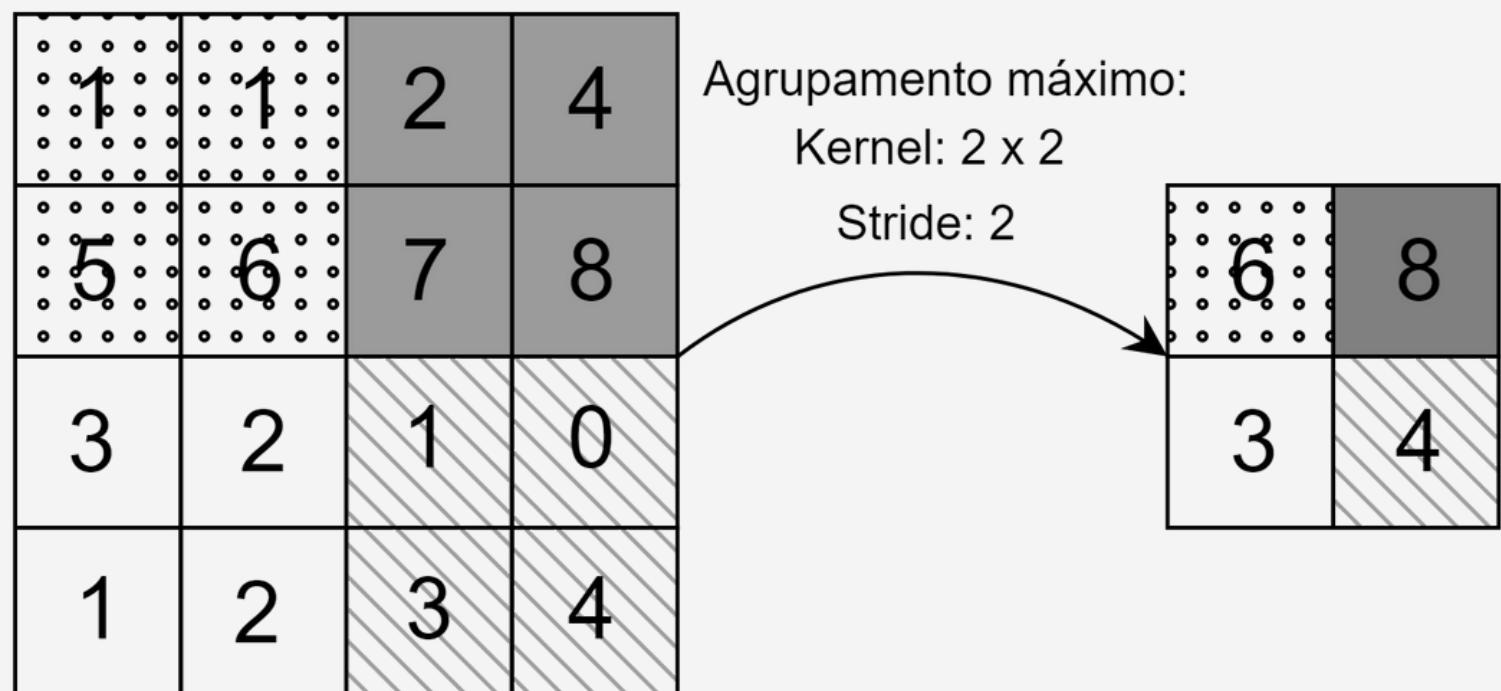
Saída: mapa de características obtido a partir da convolução da entrada com um kernel aprendido, seguido da aplicação de uma função de ativação não linear.



REDES CONVOLUCIONAIS

Camada de agrupamento

Função: reduzir o tamanho espacial da representação, reduzindo também a quantidade de parâmetros da rede.



$$l_2 = (l_1 - F) / S + 1$$

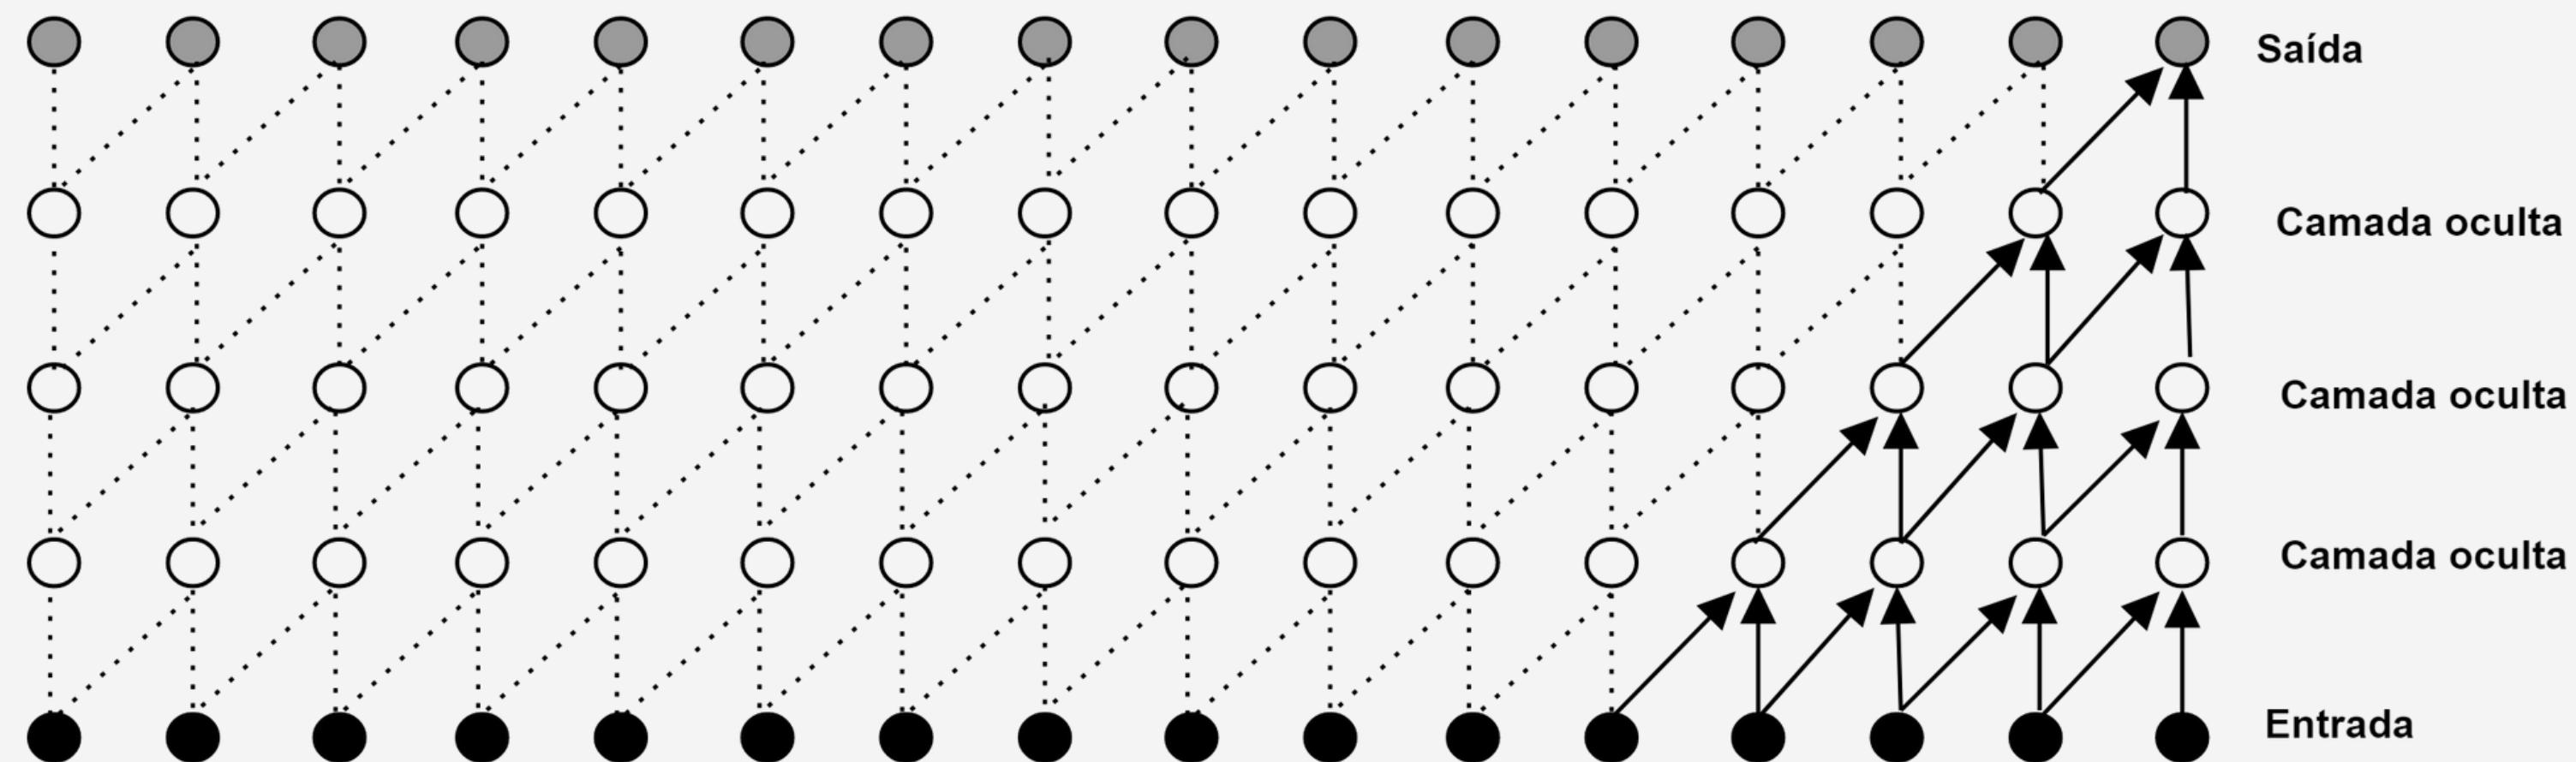
REDES CONVOLUCIONAIS TEMPORAIS

Características:

- 1 As circunvoluções na arquitetura são causais, ou seja, não há vazamento de informações do futuro para o passado.
- 2 A rede produz uma saída com o mesmo comprimento da entrada, como nas redes recorrentes.

REDES CONVOLUCIONAIS TEMPORAIS

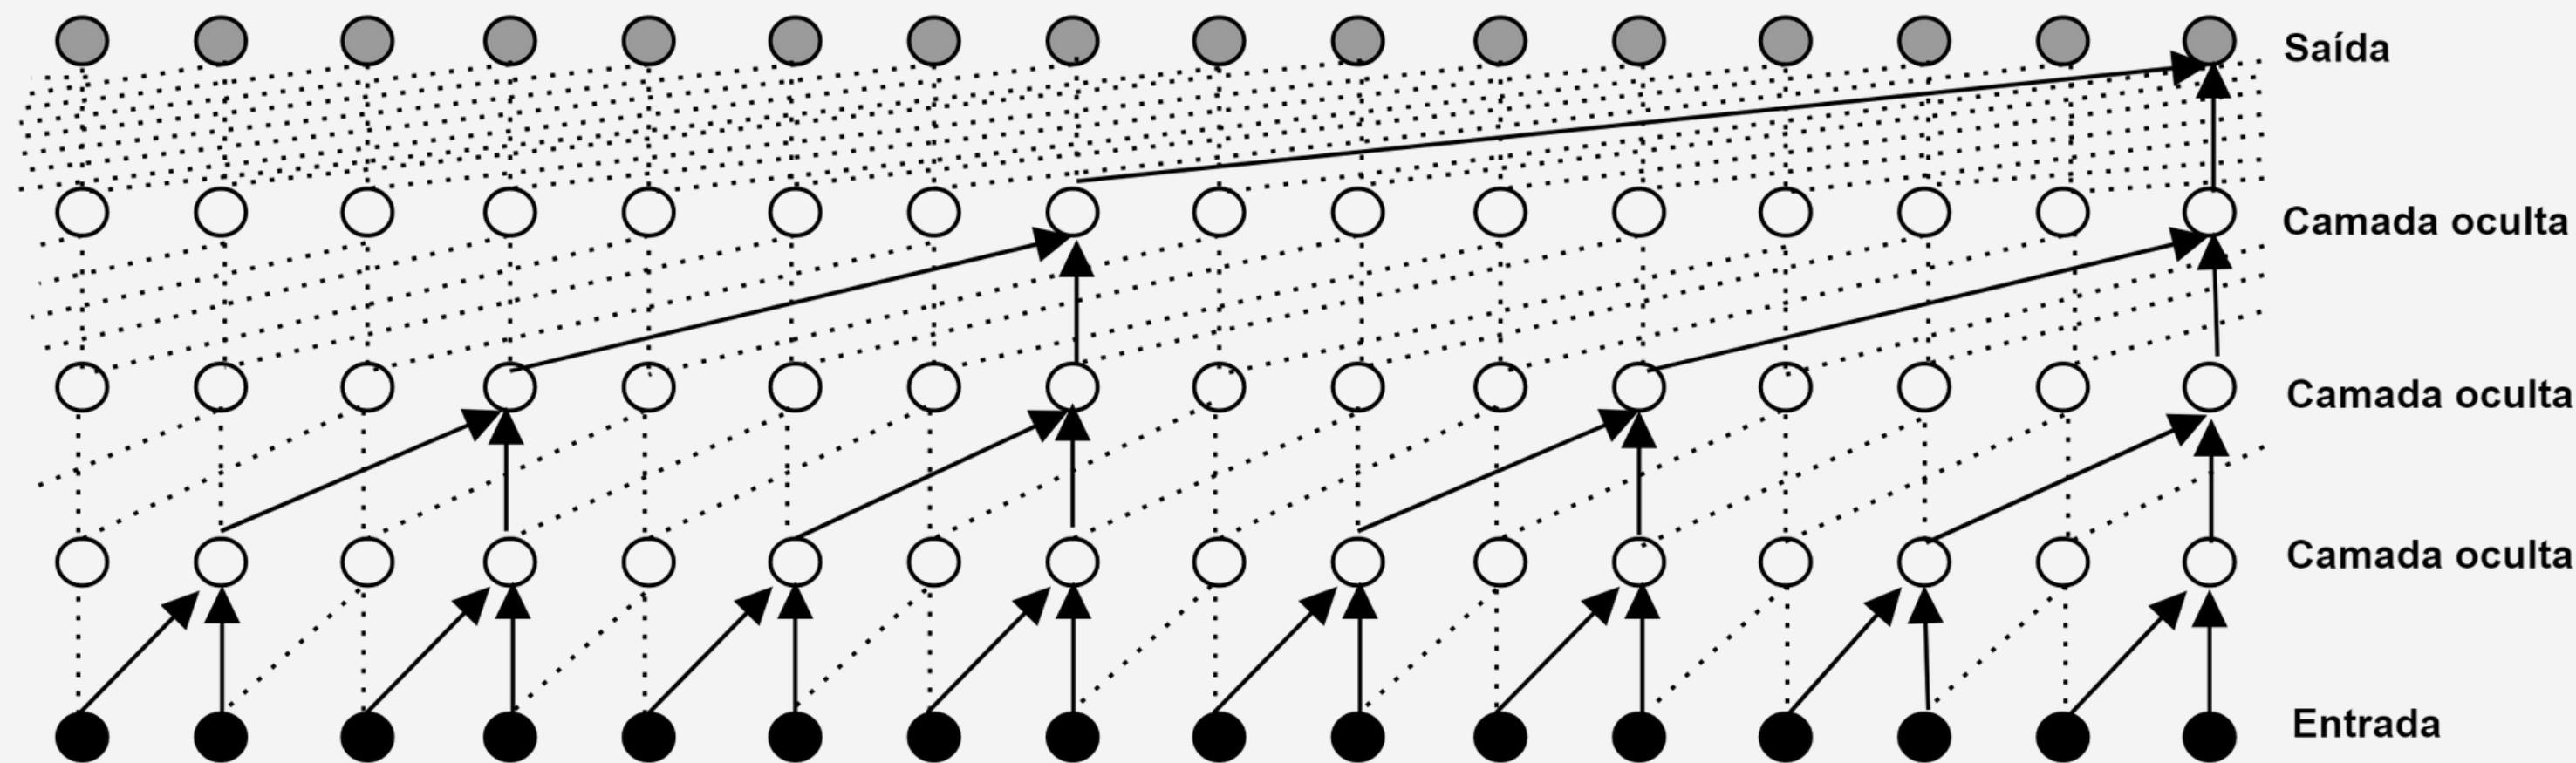
Camada convolucional causal:



Exemplo: para um campo receptivo de tamanho 5 e kernel de tamanho 2, precisa-se de 4 camadas para fazer 1 predição.

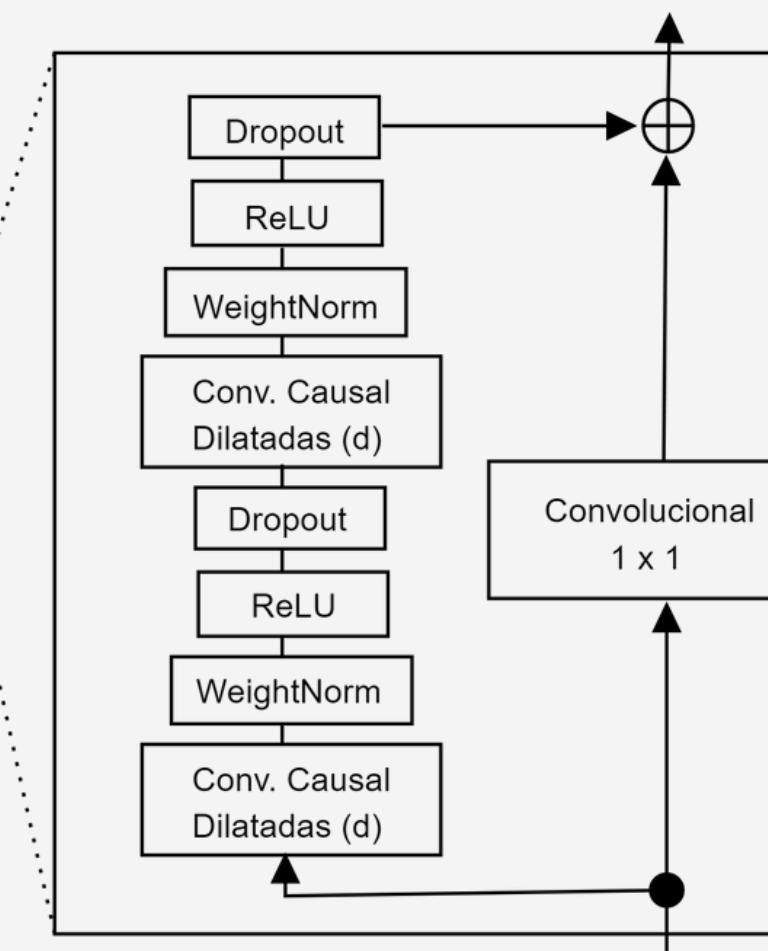
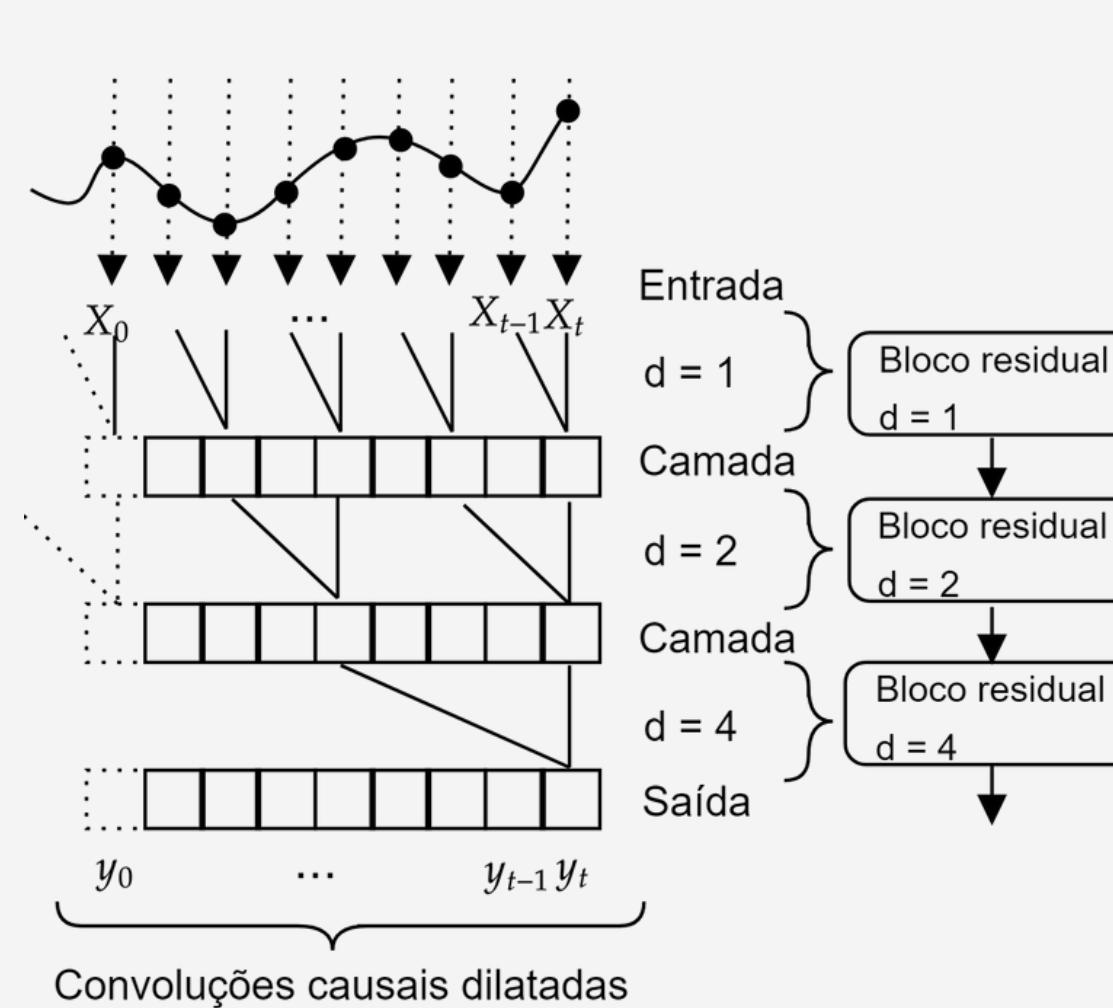
REDES CONVOLUCIONAIS TEMPORAIS

Camada convolucional causal dilatada:



Exemplo: com o mesmo número de camadas e tamanho do kernel, as dilatações permitem um campo receptivo de tamanho 16.

REDES CONVOLUCIONAIS TEMPORAIS



Blocos residuais:

São compostos por uma série de transformações F , cujas saídas são adicionadas à entrada X do bloco.

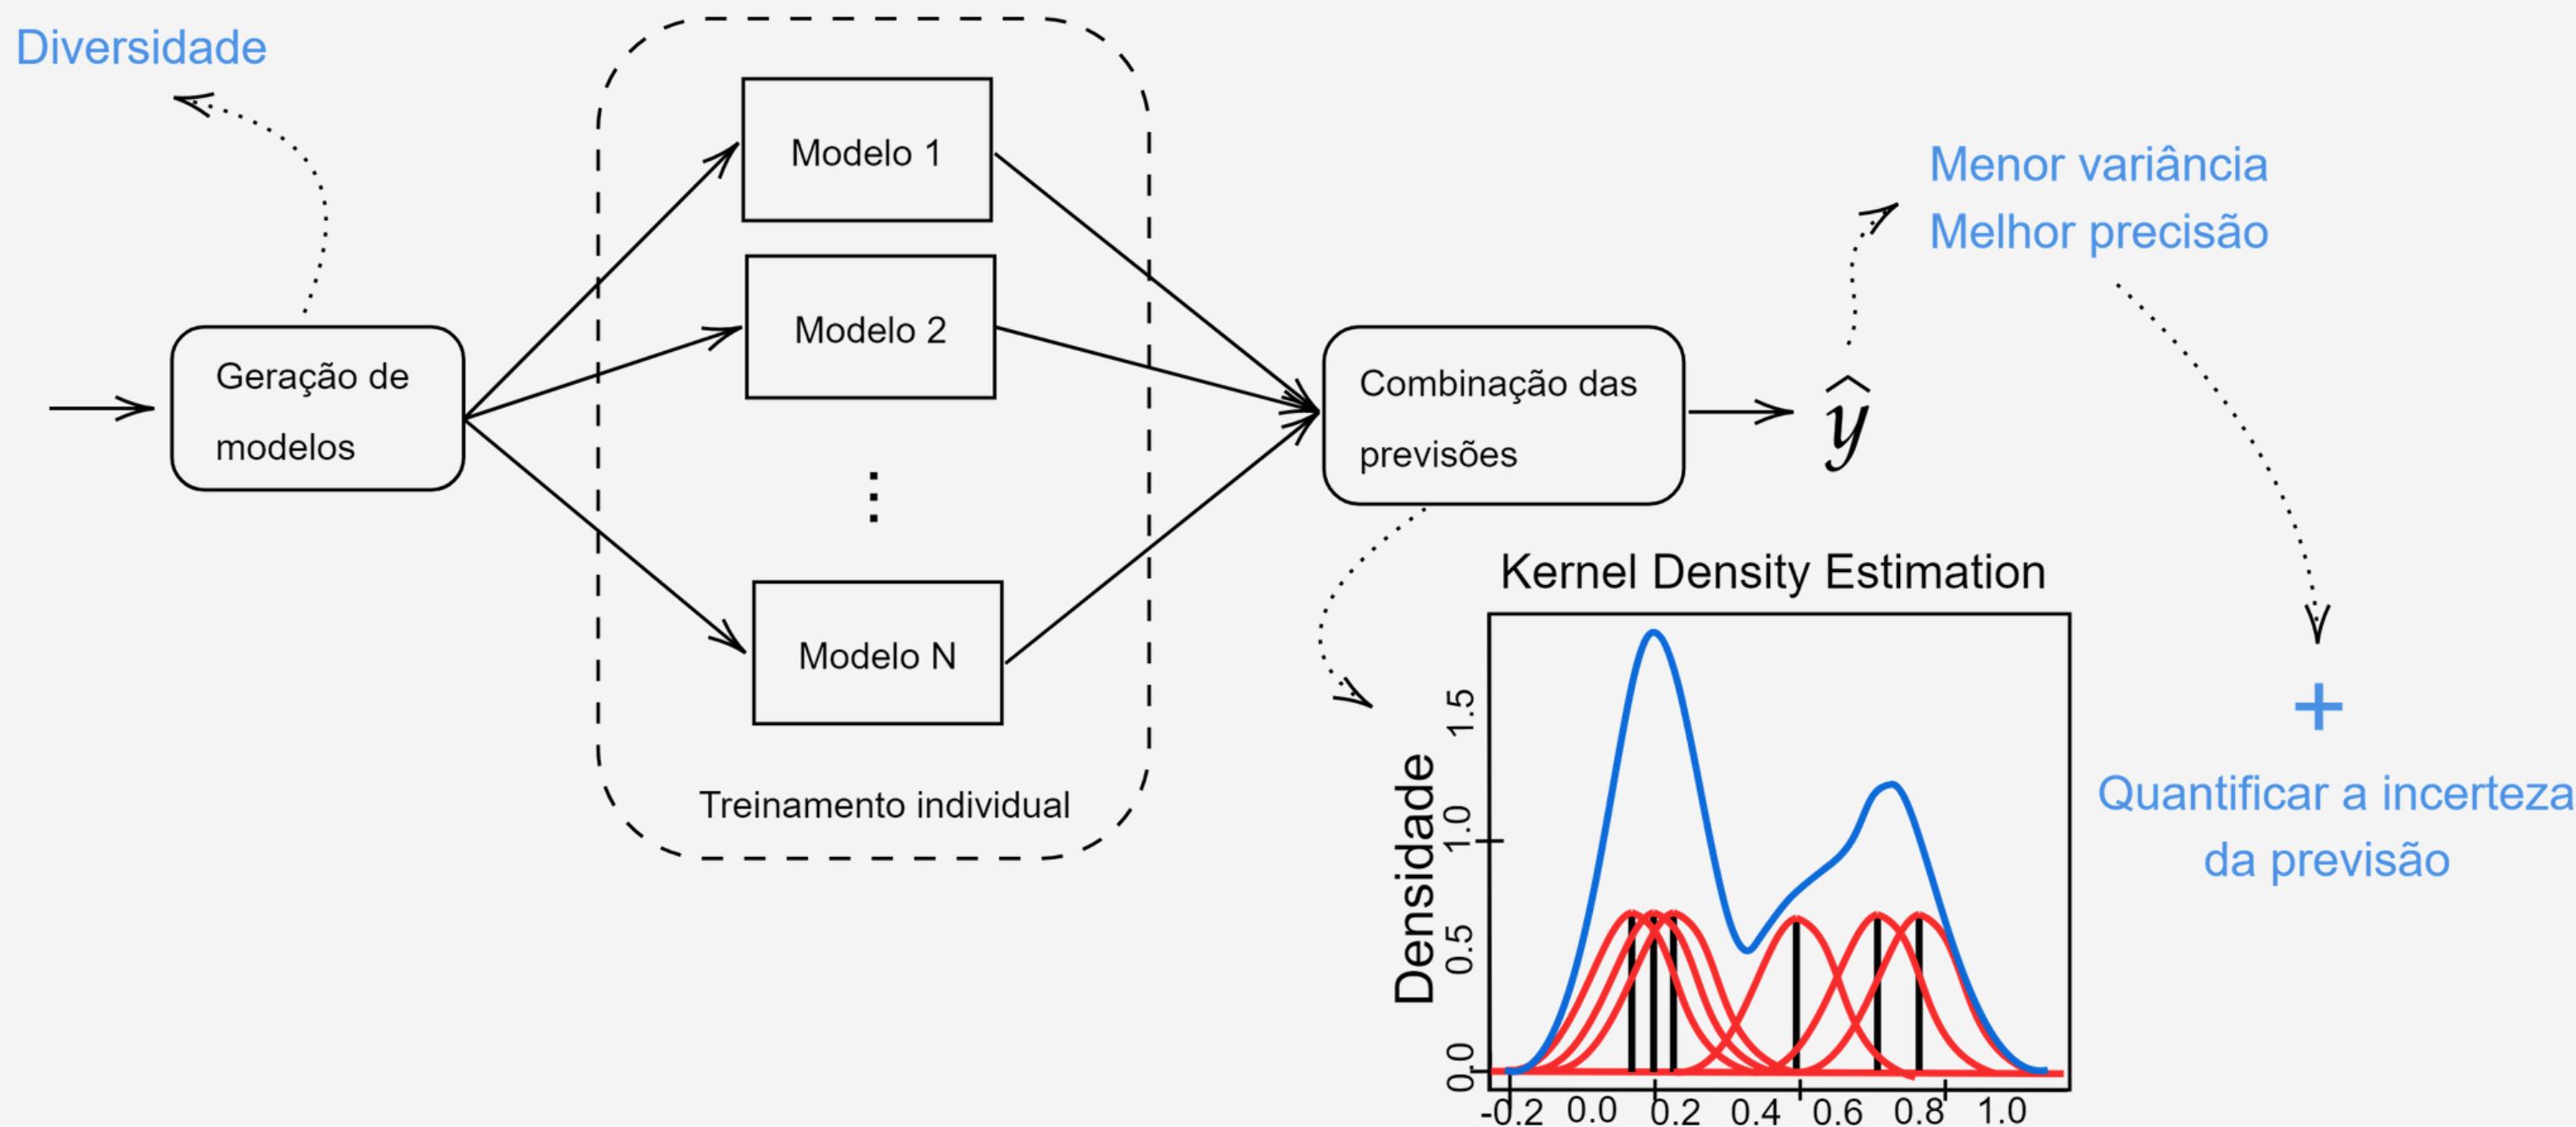
Campo receptivo:

Para um tamanho de kernel (k) e dilatações exponencialmente crescentes (d), um TCN com n pilhas de blocos residuais terá um campo receptivo:

$$r = nkd$$

ENSEMBLE LEARNING

Etapas:



OTIMIZAÇÃO DE HIPERPARÂMETROS

O problema de otimização:

Otimize:

$$\text{minimize} \quad f_1 = N^{-1} \sum_{i=0}^N RMSE(i)$$

$$\text{minimize} \quad f_2 = \|w\|_0$$

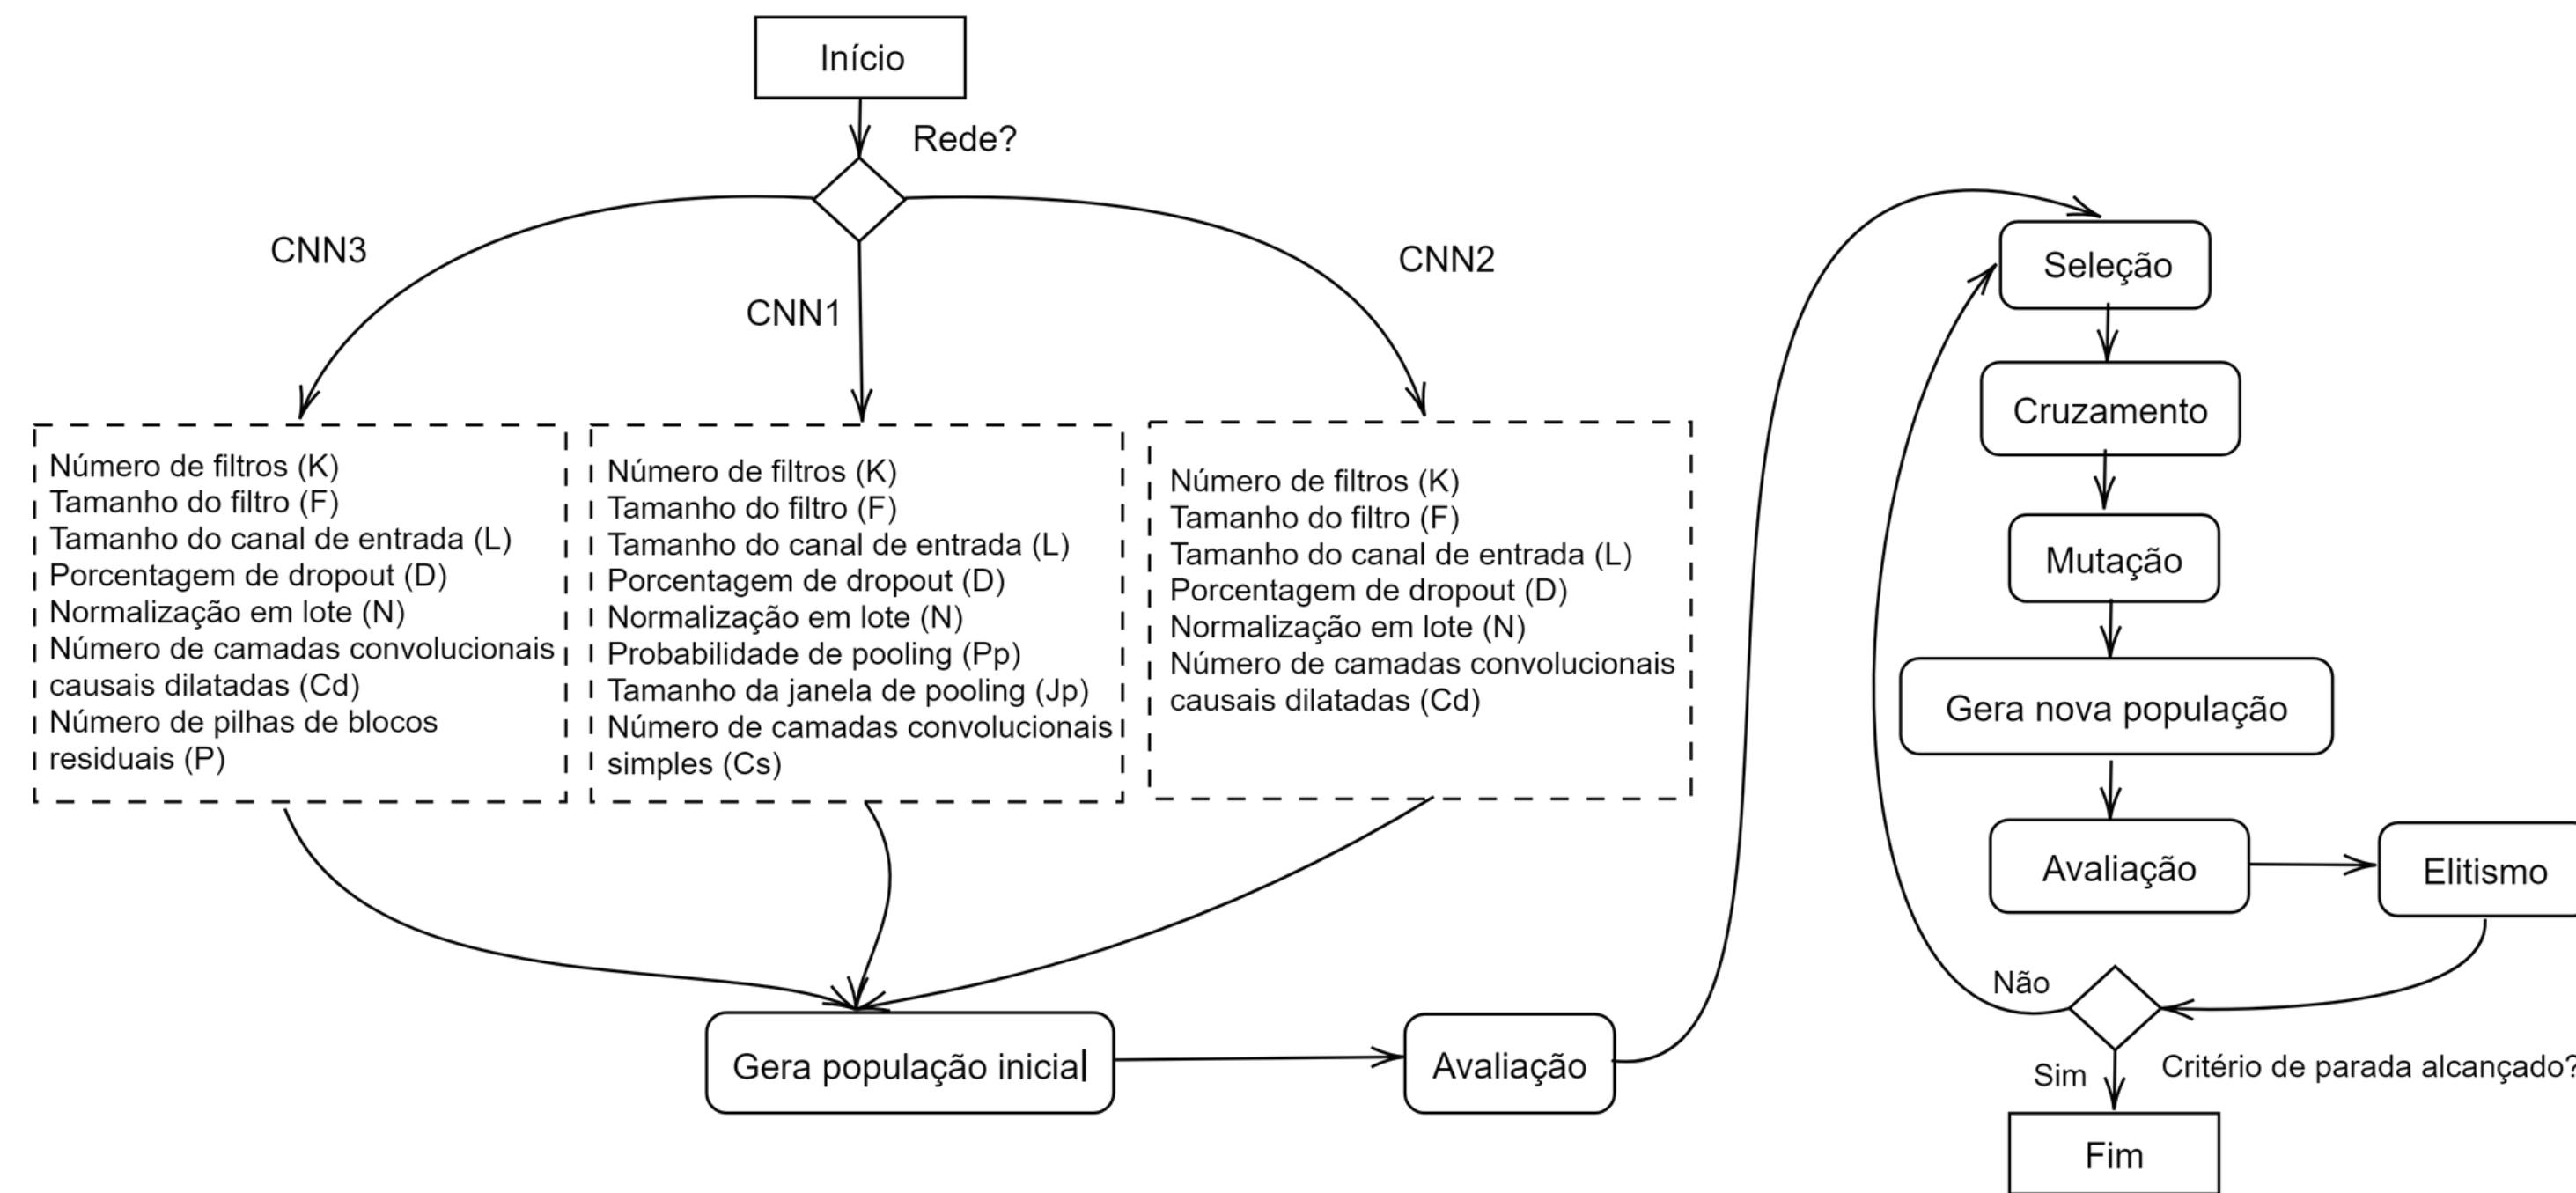
Onde:

$$RMSE = \sqrt{\sum_{t=0}^n (y(t) - \hat{y}(t))^2}$$

w = vetor de parâmetros da rede

OTIMIZAÇÃO DE HIPERPARÂMETROS

O algoritmo genético:



OTIMIZAÇÃO DE HIPERPARÂMETROS

Espaços de busca dos hiperparâmetros

Hiperparâmetro	Espaço de busca
K	[16,32,64]
F	[2,3,5,11]
L	[1.. 50]
D	[0.. 0.5]
N	Sim, Não
P_p	[0, 50, 100]
J_p	[2,3,4,5]
C_s	[1.. 5]

CNN1

Hiperparâmetro	Espaço de busca
K	[16,32,64]
F	[2,3,5,11]
D	[0.. 0.5]
N	Sim, Não
C_d	[1.. 5]
L	$[(2^{C_d}).. (2^{C_d} \cdot F)]$

CNN2

Hiperparâmetro	Espaço de busca
K	[16,32,64]
F	[2,3,5,11]
D	[0.. 0.5]
N	Sim, Não
C_d	[1.. 5]
P	[1,2]
L	$[(2^{C_d}).. (2^{C_d} \cdot F \cdot P)]$

CNN3

OTIMIZAÇÃO DE HIPERPARÂMETROS

Geração da população inicial

Número de indivíduos: 10

O indivíduo: é um vetor de hiperparâmetros.

População: gerada aleatoriamente dentro dos limites do espaço de busca de cada hiperparâmetros.

Hiperparâmetros fixos:

Variável	Parâmetro	Valor
S_c	Stride de convolução	1
R	Regularização dos pesos	3
T	Taxa de aprendizado	0.1
O	Algoritmo de otimização	Adam
A	Função de ativação	ReLU

Variável	Parâmetro	Valor
S_p	Stride da janela de pooling	2
T_p	Tipo de pooling	Máx

CNN1

CNN1, CNN2 e CNN3

23/44

OTIMIZAÇÃO DE HIPERPARÂMETROS

Avaliação

T = 9 anos da série temporal de ETo.

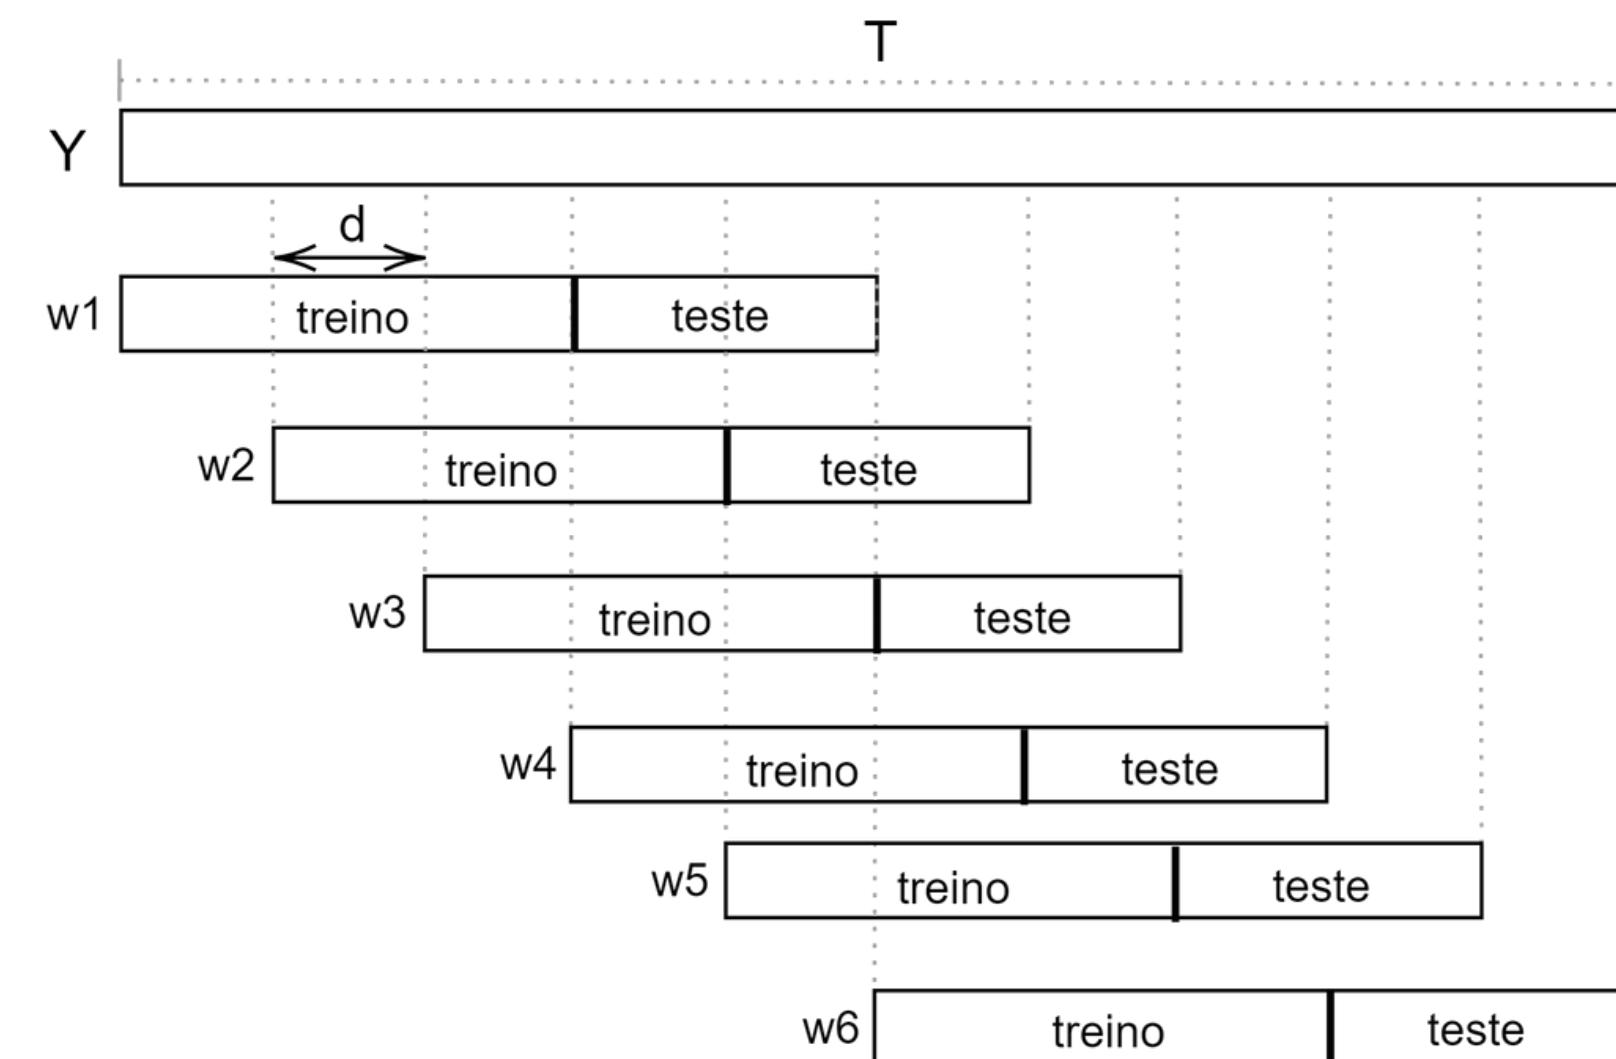
treino = 70% teste = 30%

N = 6

Métricas de avaliação:

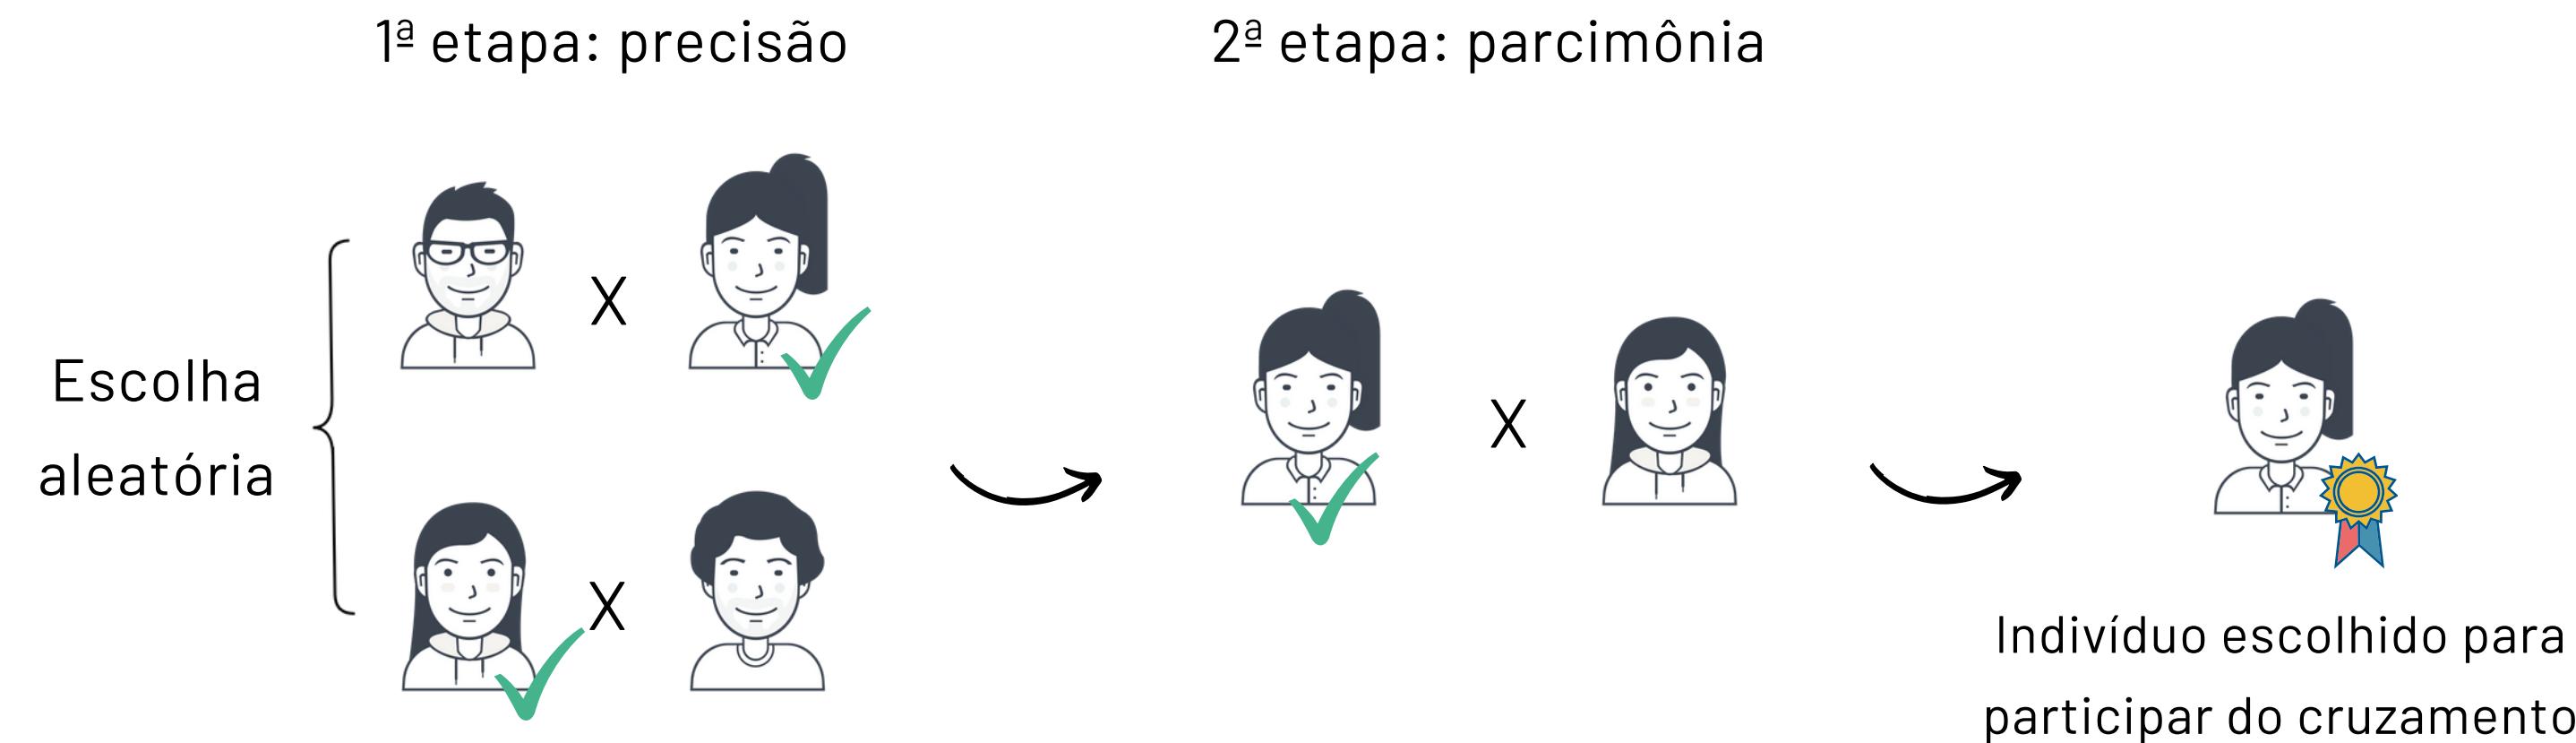
$$f_1 = N^{-1} \sum_{i=0}^N RMSE(i)$$

$$f_2 = \|w\|_0$$



OTIMIZAÇÃO DE HIPERPARÂMETROS

Seleção



TORNEIO DUPLO

OTIMIZAÇÃO DE HIPERPARÂMETROS

Cruzamento

Tipo de hiperparâmetro	Forma de cruzamento
\Re^+	$\text{Filho} = 0.7 \text{ } Pai_1 + 0.3 \text{ } Pai_2$
Categóricos	$\text{Filho} = Pai_1$ com probabilidade 0.7 ou Pai_2 , caso contrário.
L (CNN2 e CNN3)	Outro valor é escolhido aleatoriamente de acordo com os hiperparâmetros C_d , F e P

OBS: Pai_1 , possui melhor média de RMSE.

Mutação

Tipo de hiperparâmetro	Forma de mutação
\Re^+	Aplica-se perturbações aleatórias.
Categóricos	Outro valor é escolhido aleatoriamente.

OTIMIZAÇÃO DE HIPERPARÂMETROS

Elitismo

Mantém o melhor indivíduo da geração atual na próxima geração e descarta o pior.

Critérios de parada

1. Número fixo de gerações sem melhoria; ou
2. Número máximo de gerações.

OTIMIZAÇÃO DE HIPERPARÂMETROS

Resultados

Hiperparâmetro	Resultado
K	32
F	11 x 11
D	0
N	Sim
C_s	1
L	4
P_p	100%
J_p	3
f_1	0.76
f_2	449

CNN1

Hiperparâmetro	Resultado
K	32
F	2 x 2
D	0
N	Sim
C_d	1
L	4
f_1	0.75
f_2	449

CNN2

Hiperparâmetro	Resultado
K	16
F	3 x 3
D	0.2
N	Sim
C_d	3
P	2
L	48
f_1	0.75
f_2	68257

CNN3

OTIMIZAÇÃO DE HIPERPARÂMETROS

Resultados

Hiperparâmetro	Espaço de busca	Resultado
Número de unidades	[50..100]	72
Porcentagem de dropout	[0..0.5]	0.3
Normalização em lote	sim, não	sim
Quantidade de lags	[1..50]	3
Número de camadas	[1..5]	1

LSTM

Algoritmo genético

(p = 1, d = 1, q = 1)

ARIMA

AutoARIMA

Hiperparâmetro	Espaço de busca	Resultado
Número de partições	[10, 100]	16
Método de particionamento	grid, entropy	grid
Função de pertinência	triangular, trapezoidal, gaussiana	trapezoidal
Ordem	[1, 3]	2
α -cut	[0, 0.5]	0.2
Lags	[1, 50]	[2, 9]

WFTS

Algoritmo genético

RESULTADOS

Experimentos

Dados de treinamento: 18 anos (1993 a 2011)

Dados de teste: 2012, 2013, 2014 e 2015.

Horizontes de previsão: 1, 3, 7 e 10.

Métrica de desempenho: - ARIMA e WFTS: RMSE.

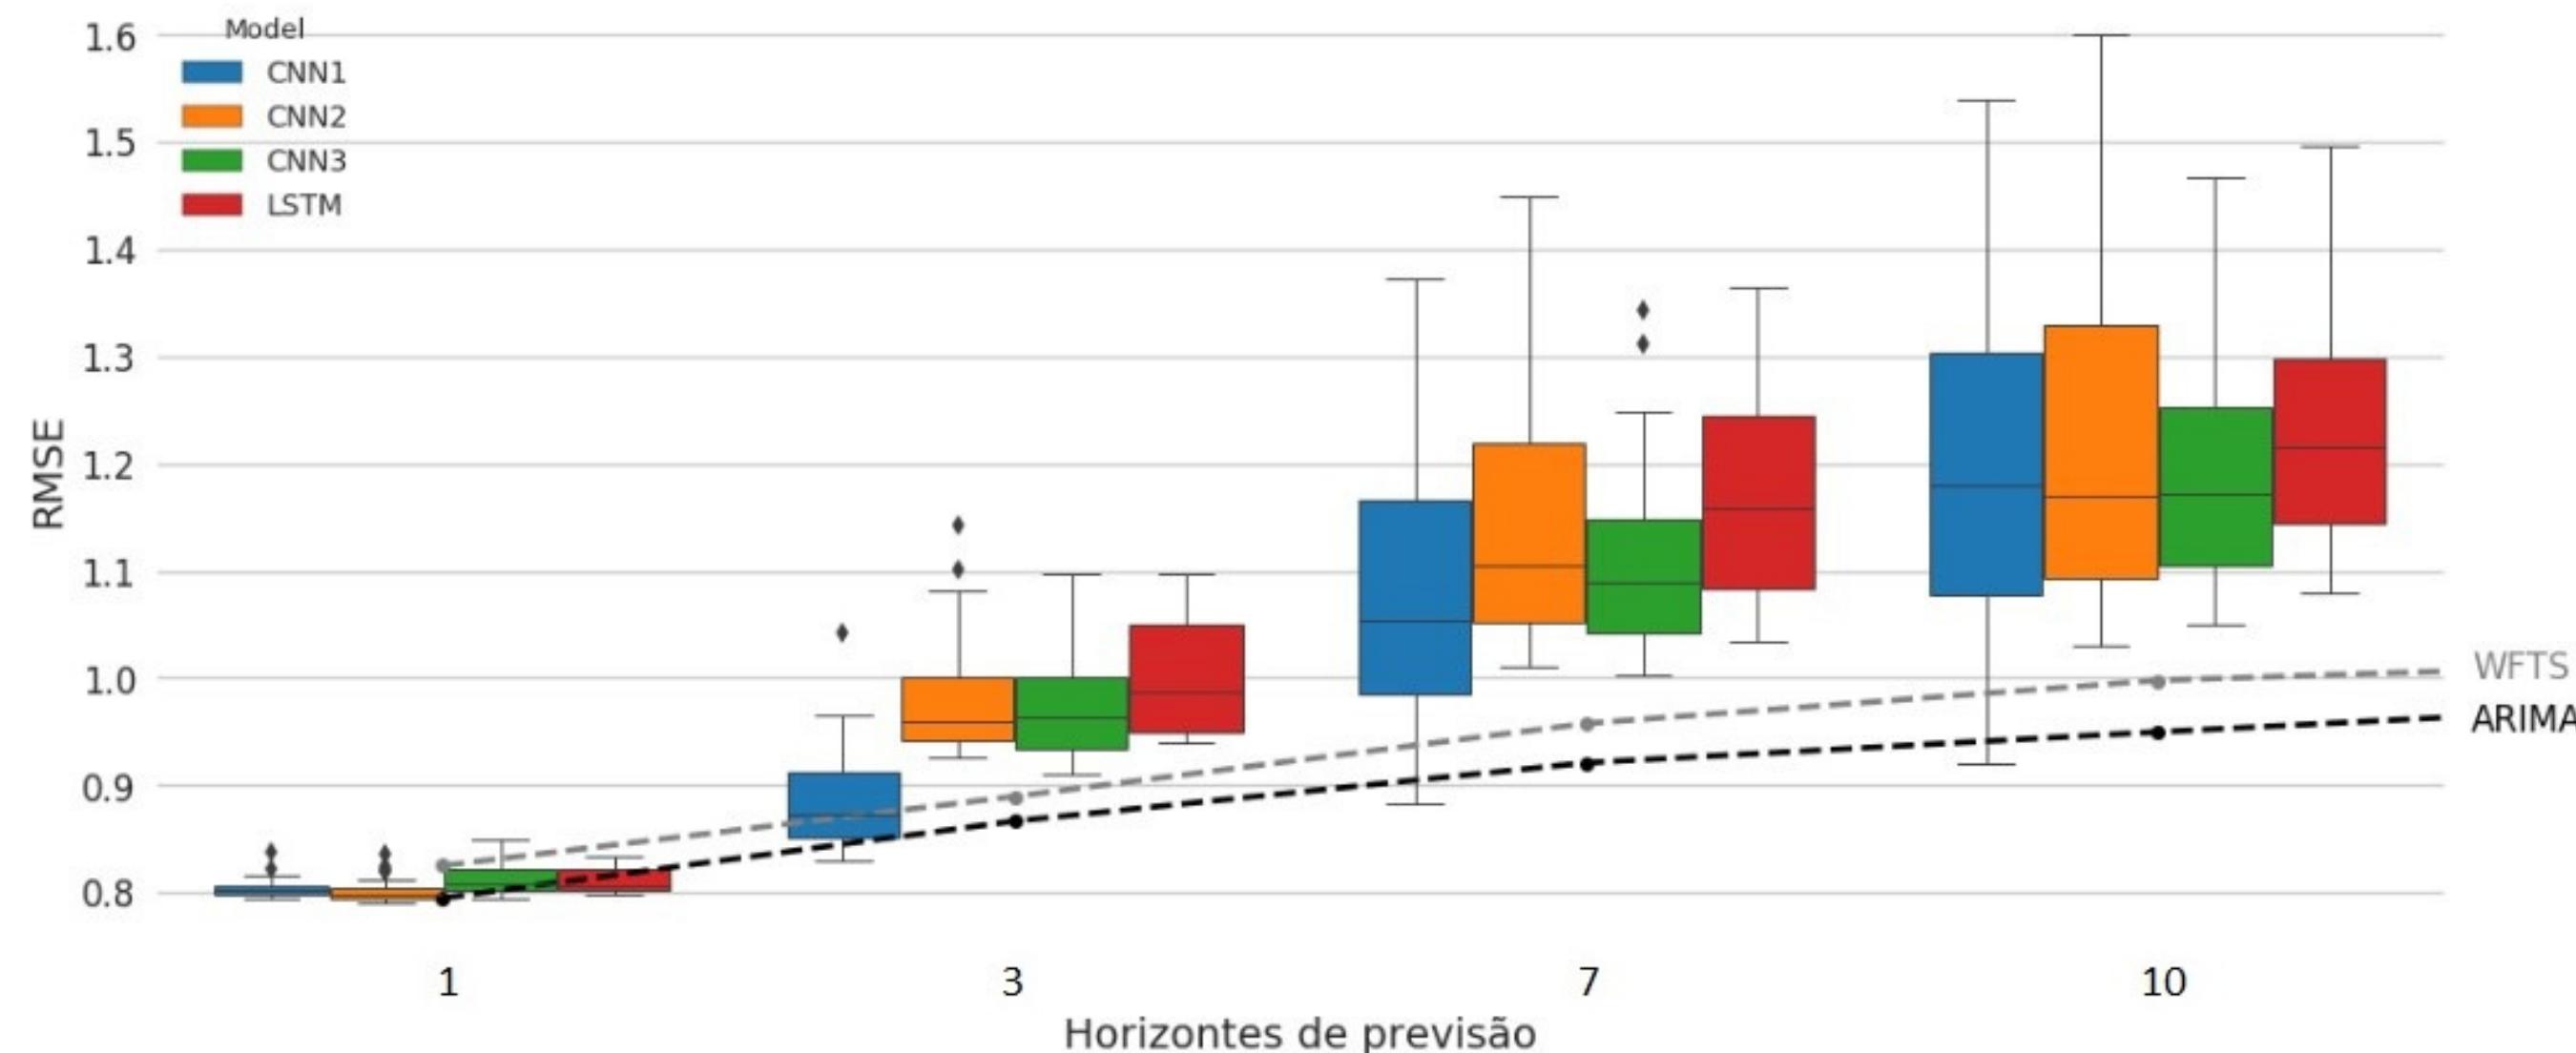
- CNN, LSTM, ensembles: média de 30 execuções desses modelos.

Os modelos CNN1, CNN2 e CNN3, resultantes da otimização dos hiperparâmetros pelo algoritmo genético, foram validados a partir da comparação com os modelos LSTM, WFTS e ARIMA.

Esses modelos também foram comparados a modelos ensemble.

RESULTADOS

Comparação entre CNNs, LSTM, WFTS e ARIMA



(2012)

RESULTADOS

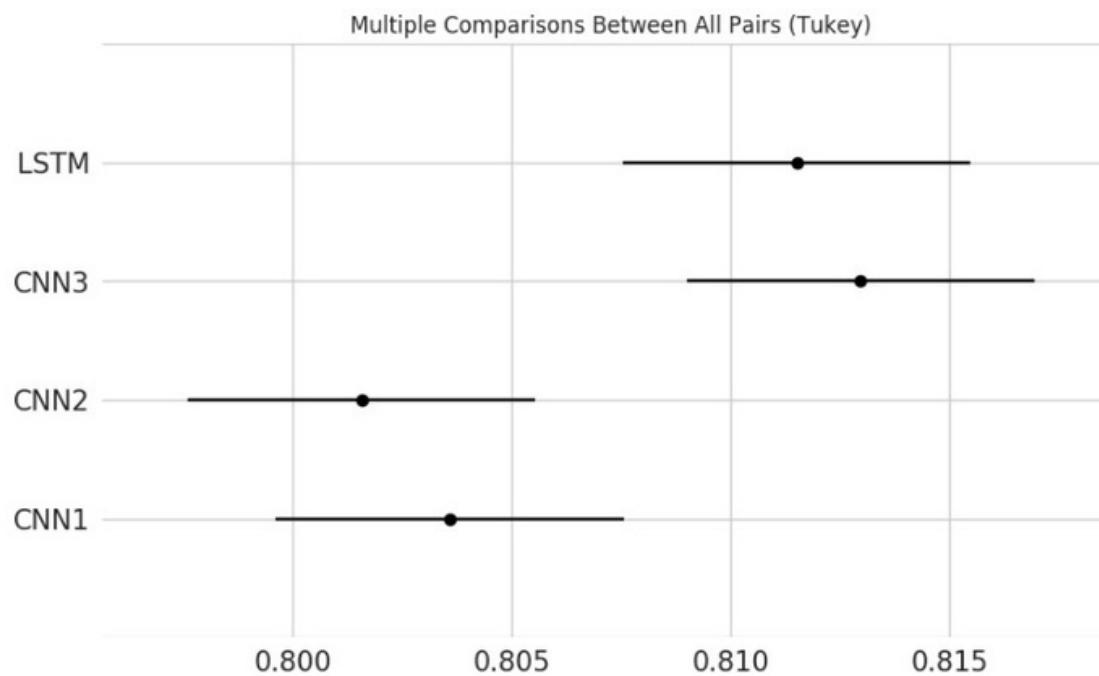
Comparação entre CNNs, LSTM, WFTS e ARIMA

Horizonte de previsão	CNN1	CNN2	CNN3	LSTM	ARIMA	WFTS
1	0.80 ±0.00	0.80 ±0.01	0.81 ±0.01	0.81 ±0.01	0.79	0.82
3	0.88 ±0.04	0.98 ±0.05	0.97 ±0.05	0.99 ±0.05	0.92	0.95
7	1.07 ±0.11	1.14 ±0.11	1.11 ±0.08	1.16 ±0.09	1.00	1.03
10	1.19 ±0.14	1.21 ±0.15	1.19 ±0.10	1.22 ±0.11	1.03	1.07

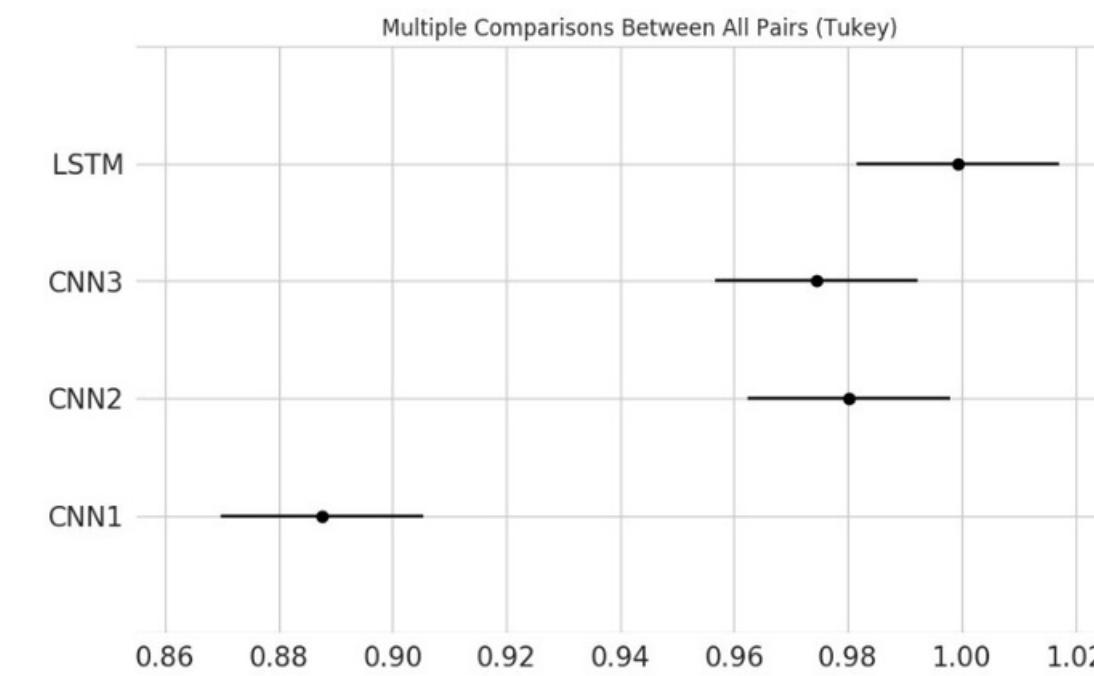
(2012)

RESULTADOS

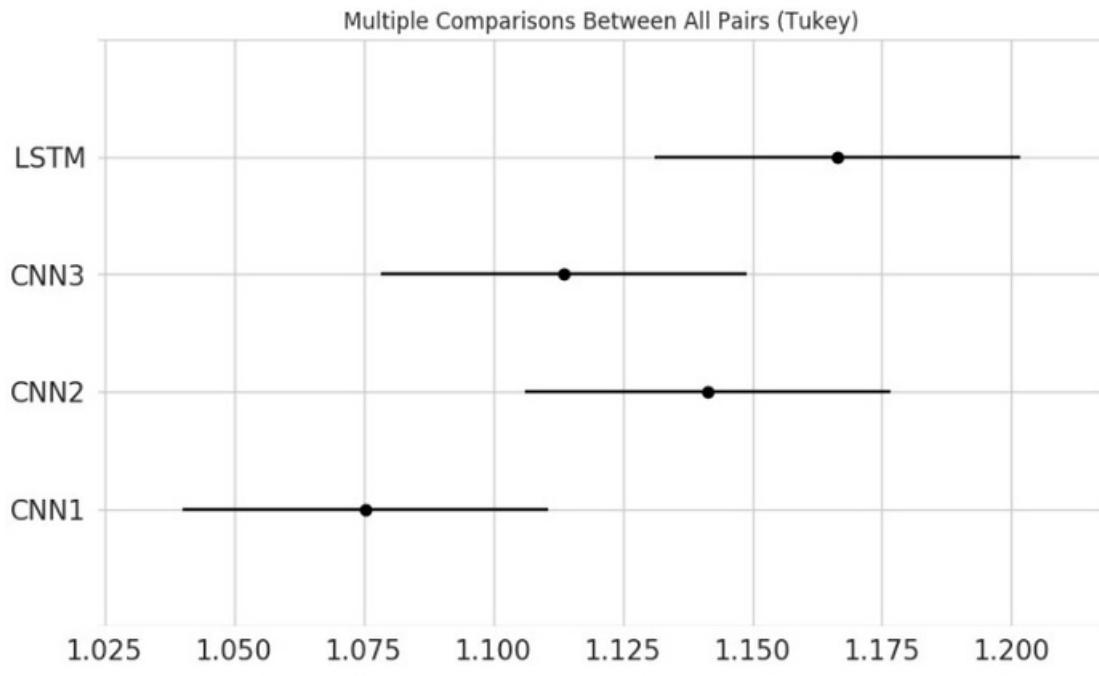
Comparação entre CNNs e LSTM (2012)



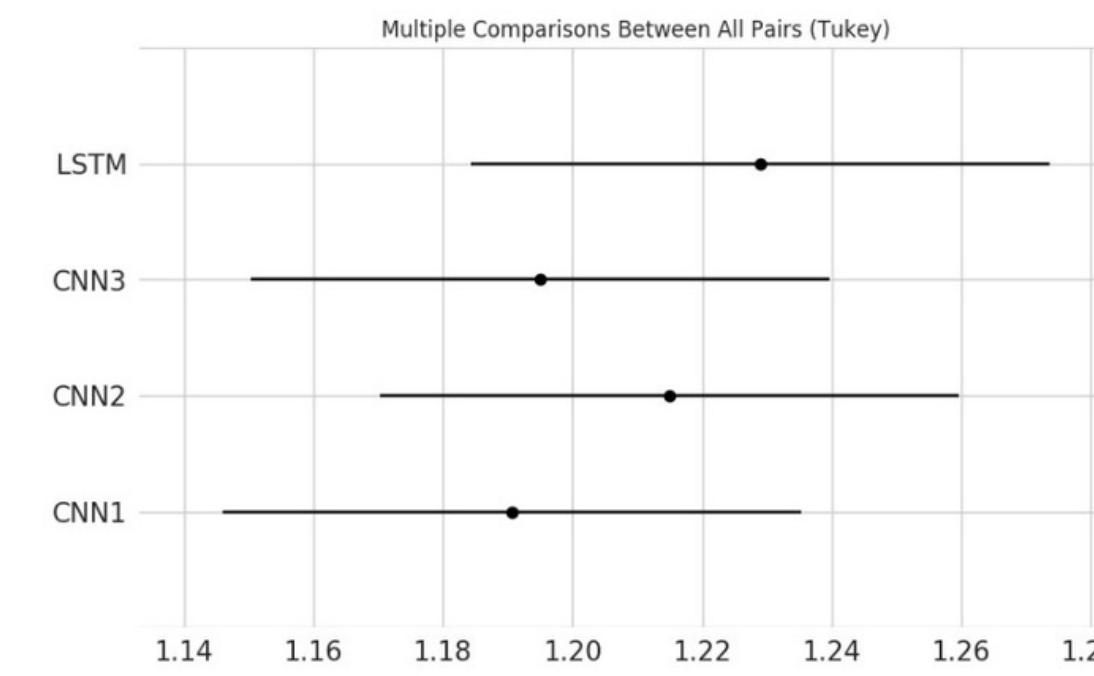
H1



H3



H7



H10

RESULTADOS

Criação dos ensembles

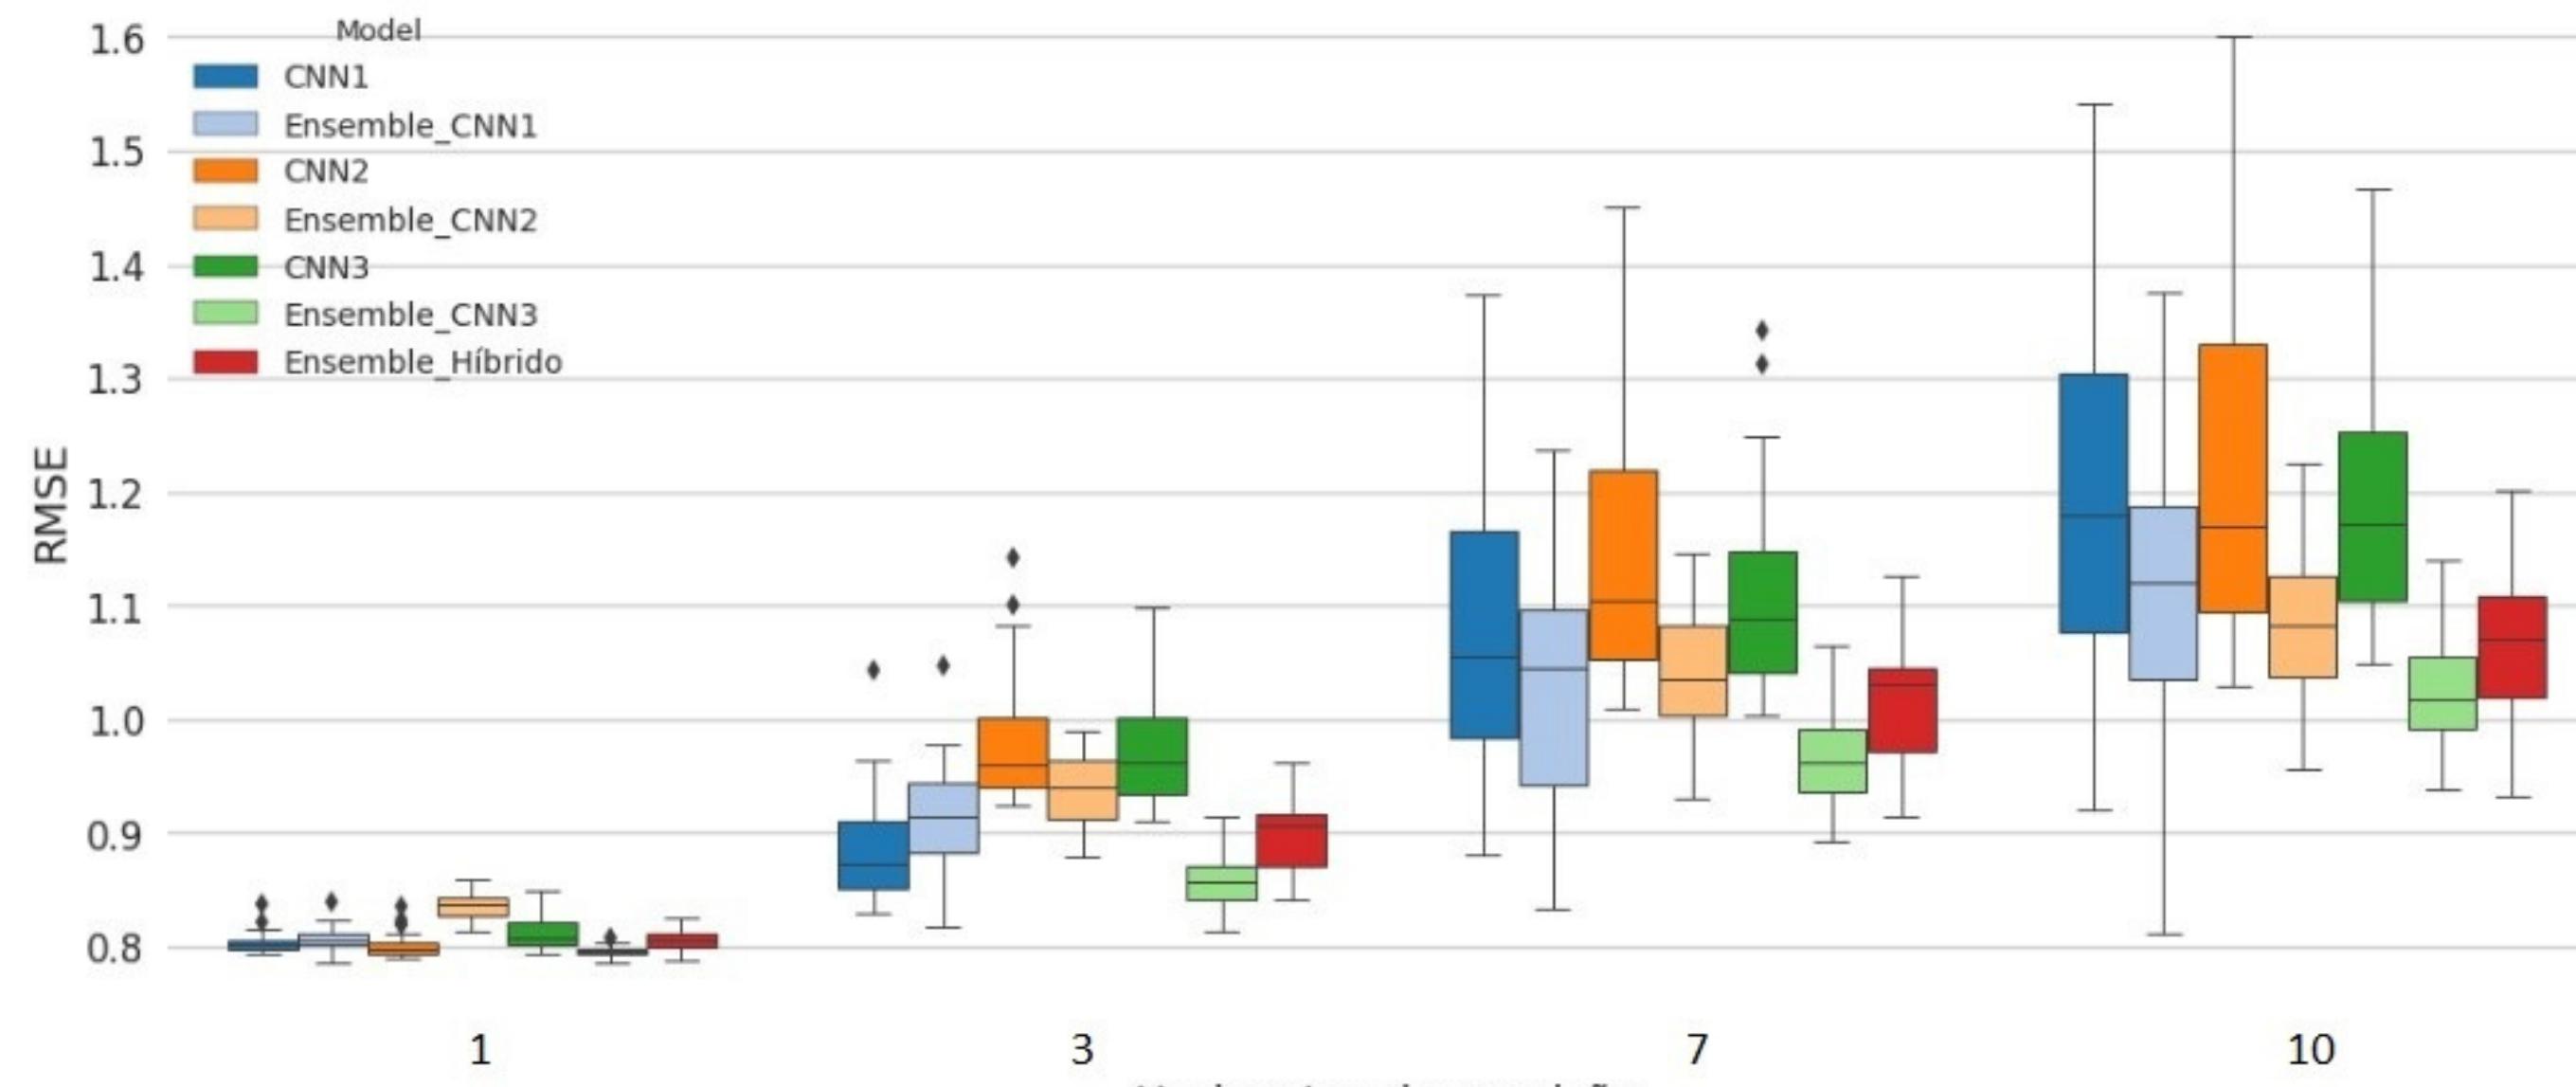
Geração dos modelos: geração aleatória de acordo com os espaços de busca usados no algoritmo genético.

Combinação das saídas: KDE com kernel gaussiano.

<i>Ensemble</i>	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5	Modelo 6
<i>Ensemble CNN1</i>	CNN1	CNN1	CNN1	CNN1	CNN1	CNN1
<i>Ensemble CNN2</i>	CNN2	CNN2	CNN2	CNN2	CNN2	CNN2
<i>Ensemble CNN3</i>	CNN3	CNN3	CNN3	CNN3	CNN3	CNN3
<i>Ensemble Híbrido</i>	CNN1	CNN1	CNN2	CNN2	CNN3	CNN3

RESULTADOS

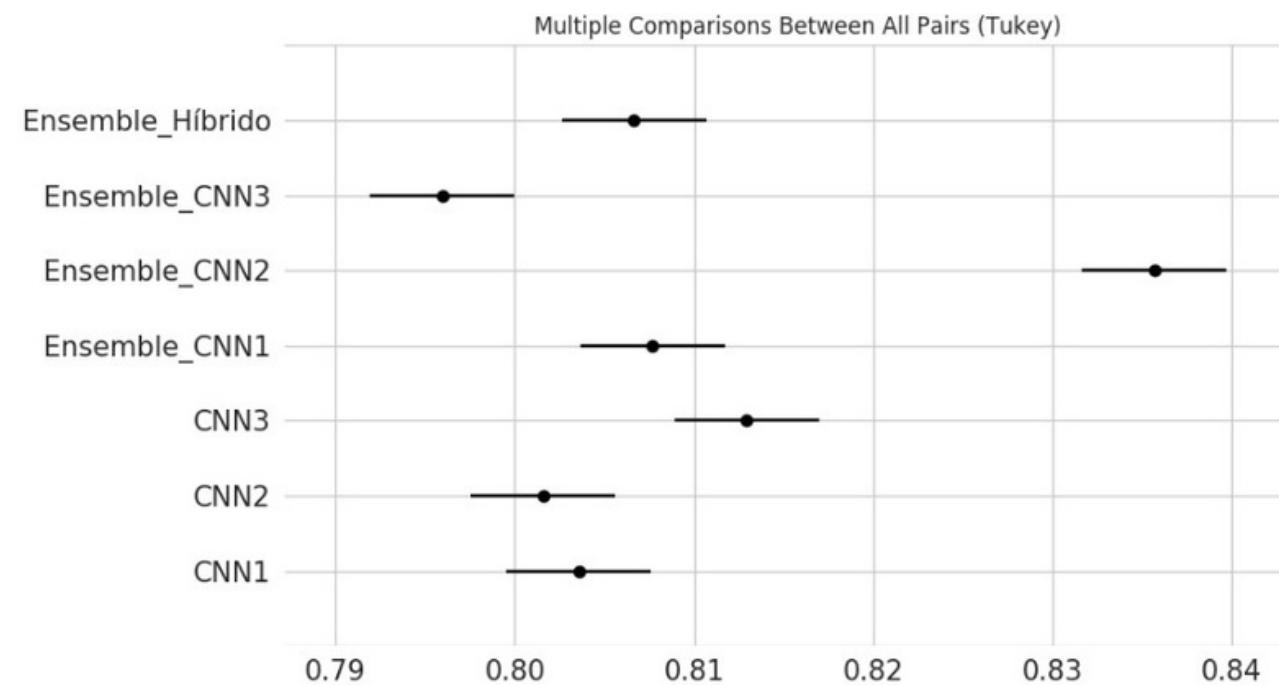
Comparação entre CNNs e ensembles



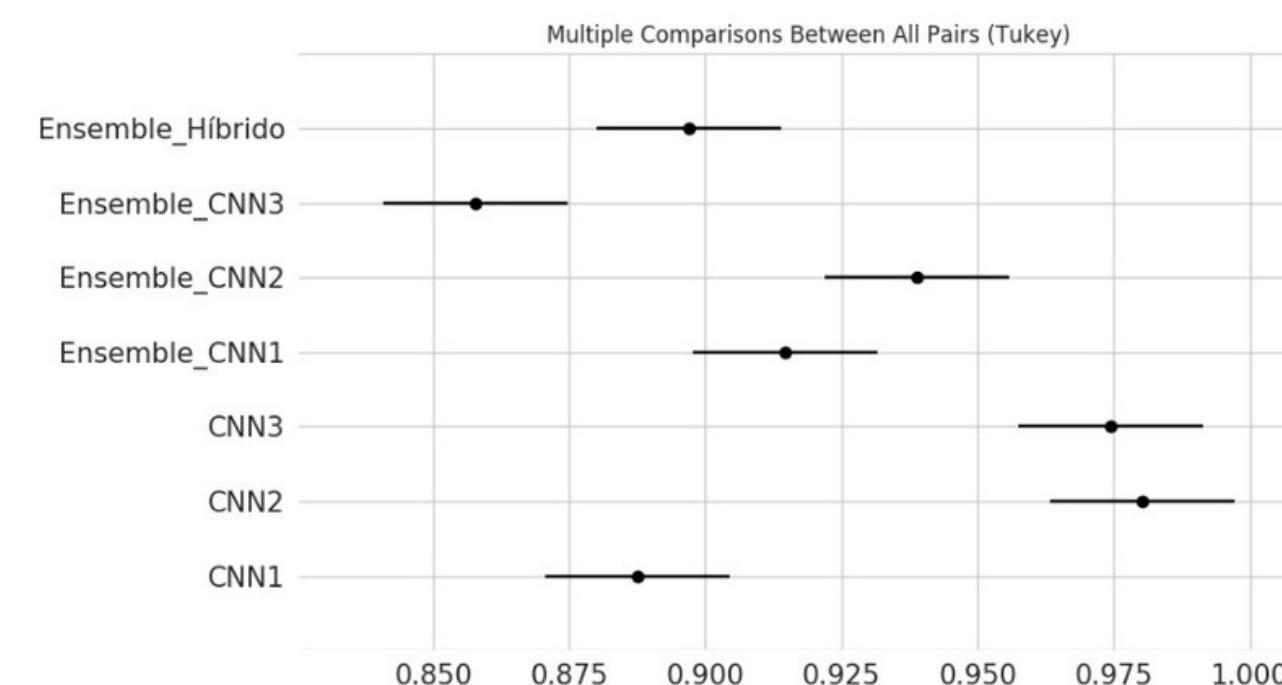
(2012)

RESULTADOS

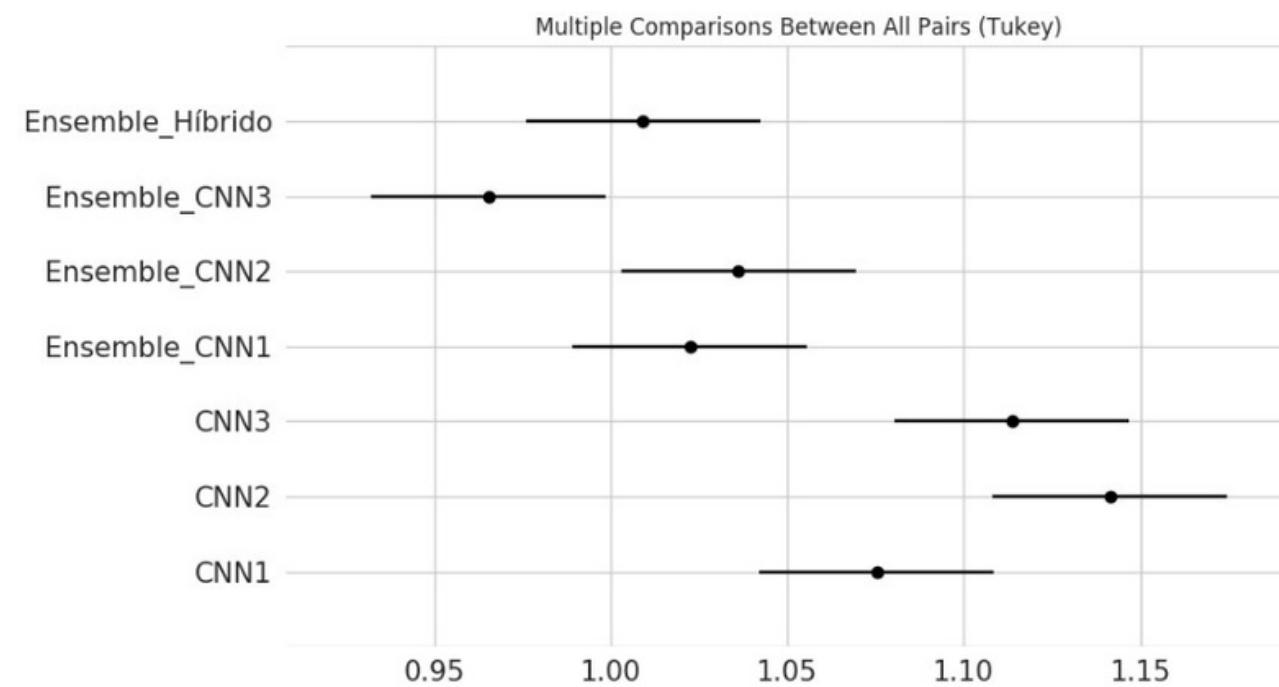
Comparação entre CNNs e ensembles (2012)



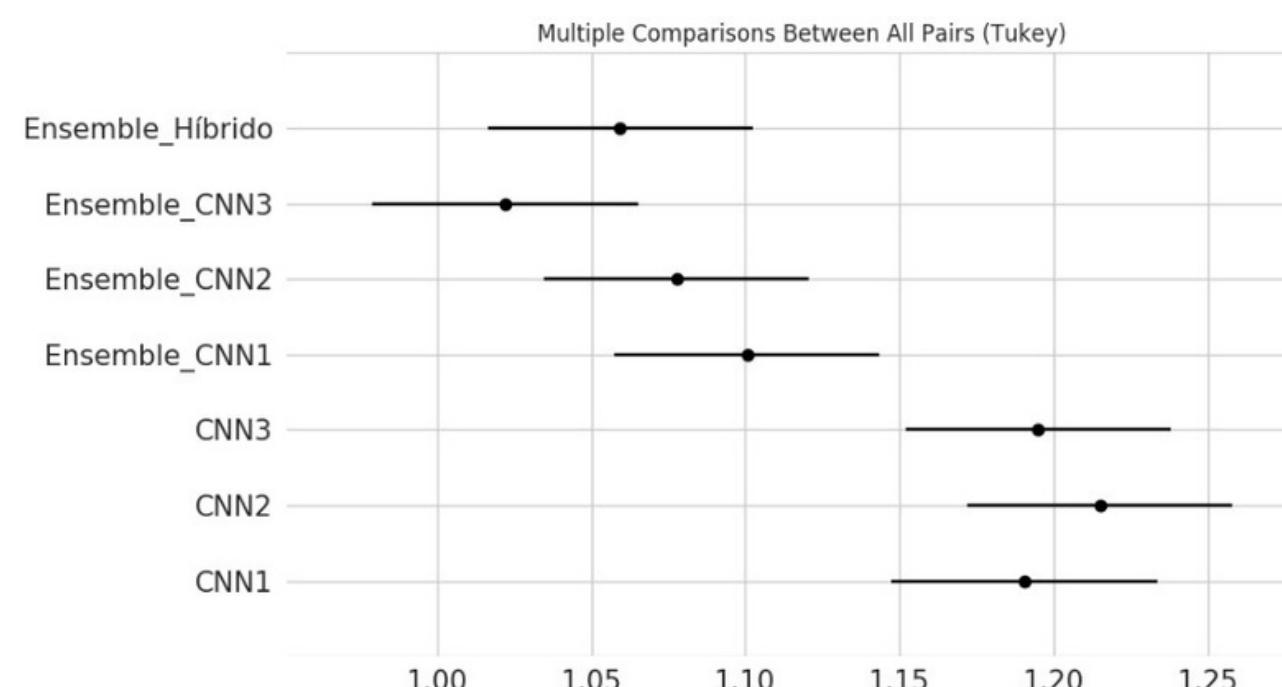
H1



H3



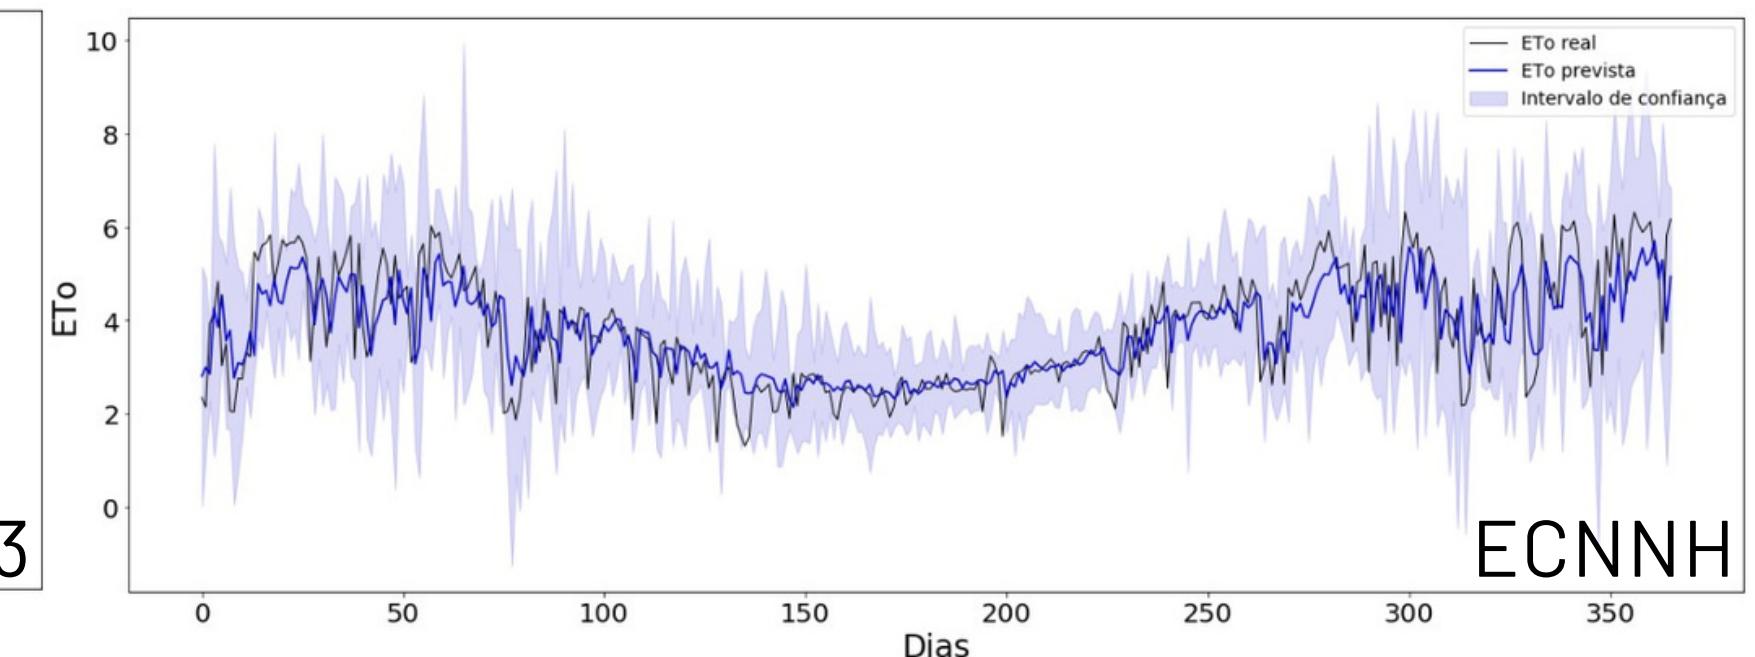
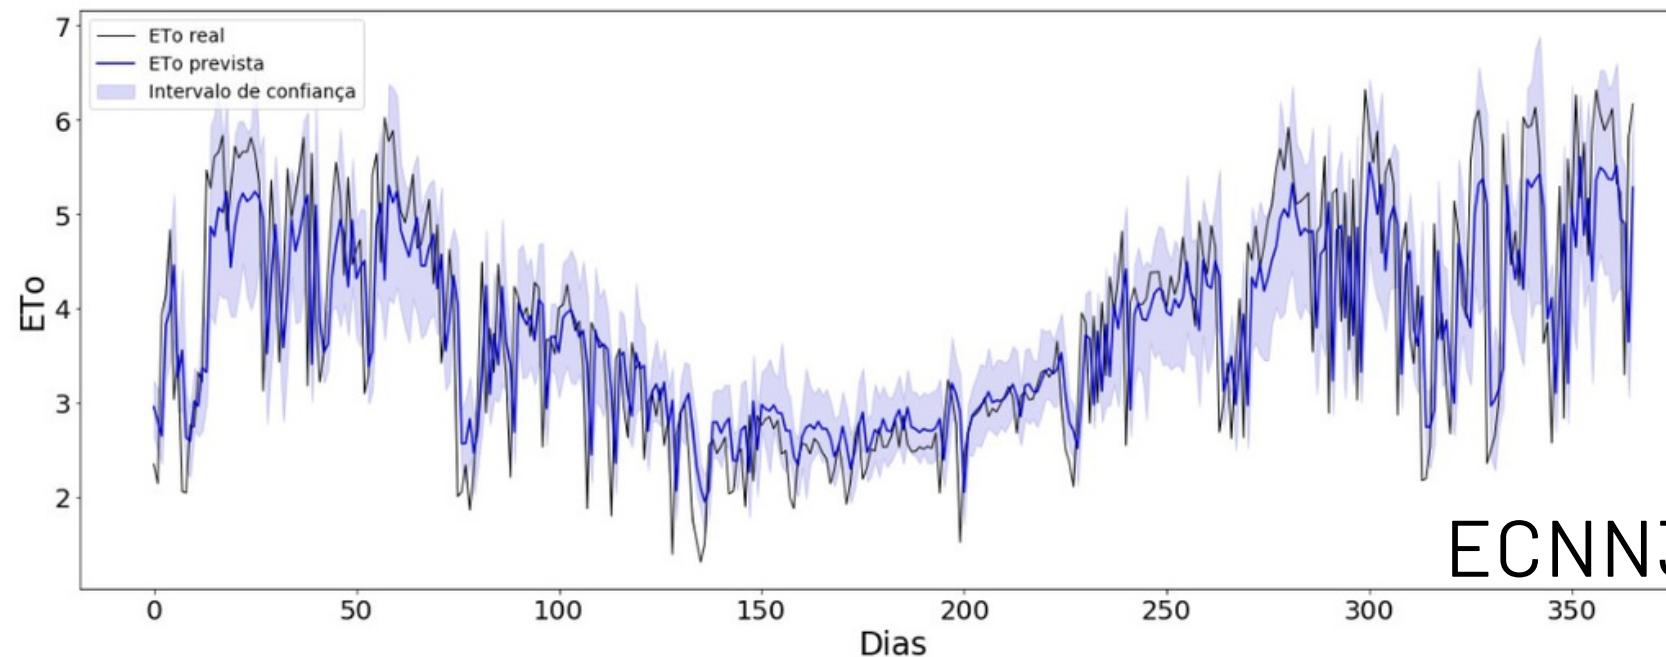
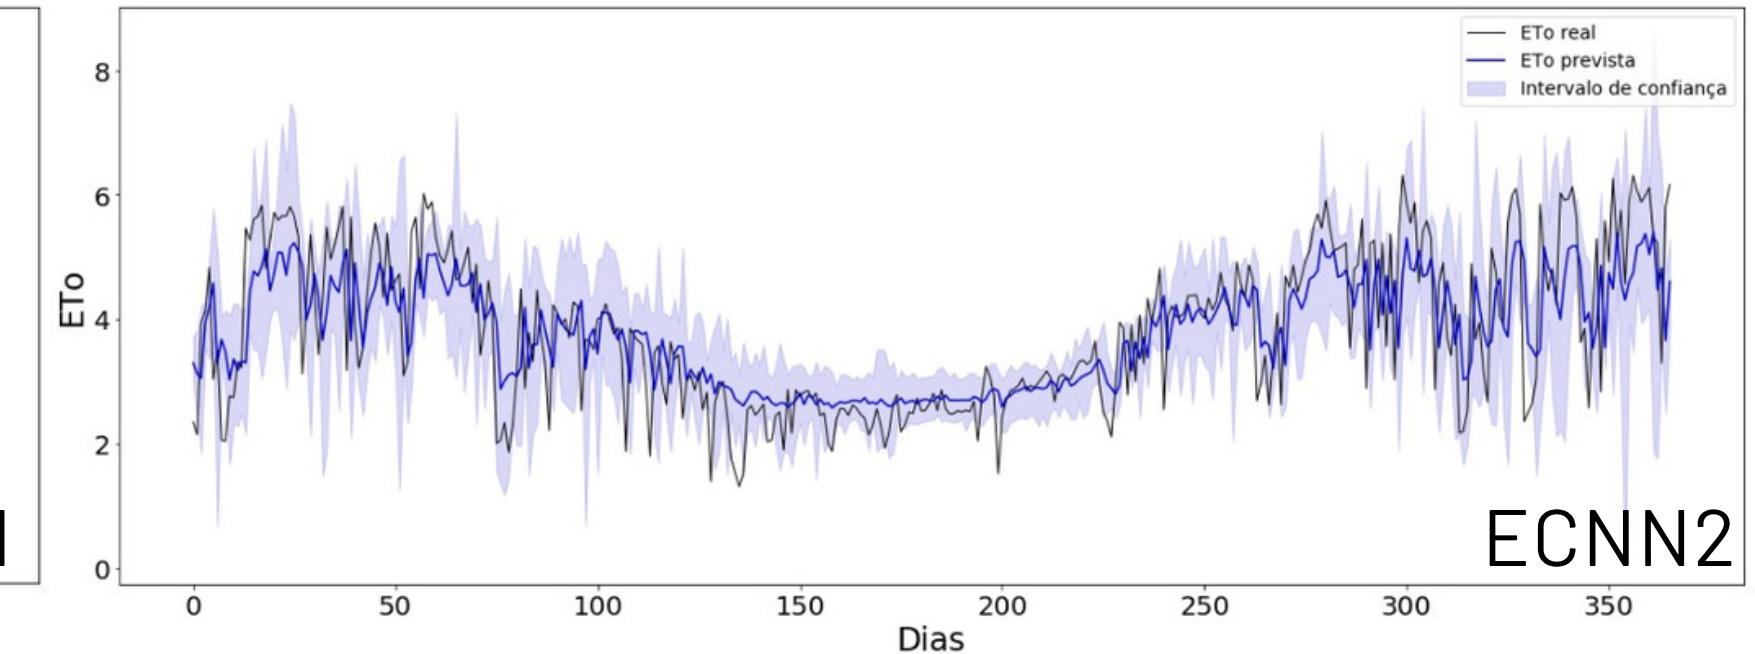
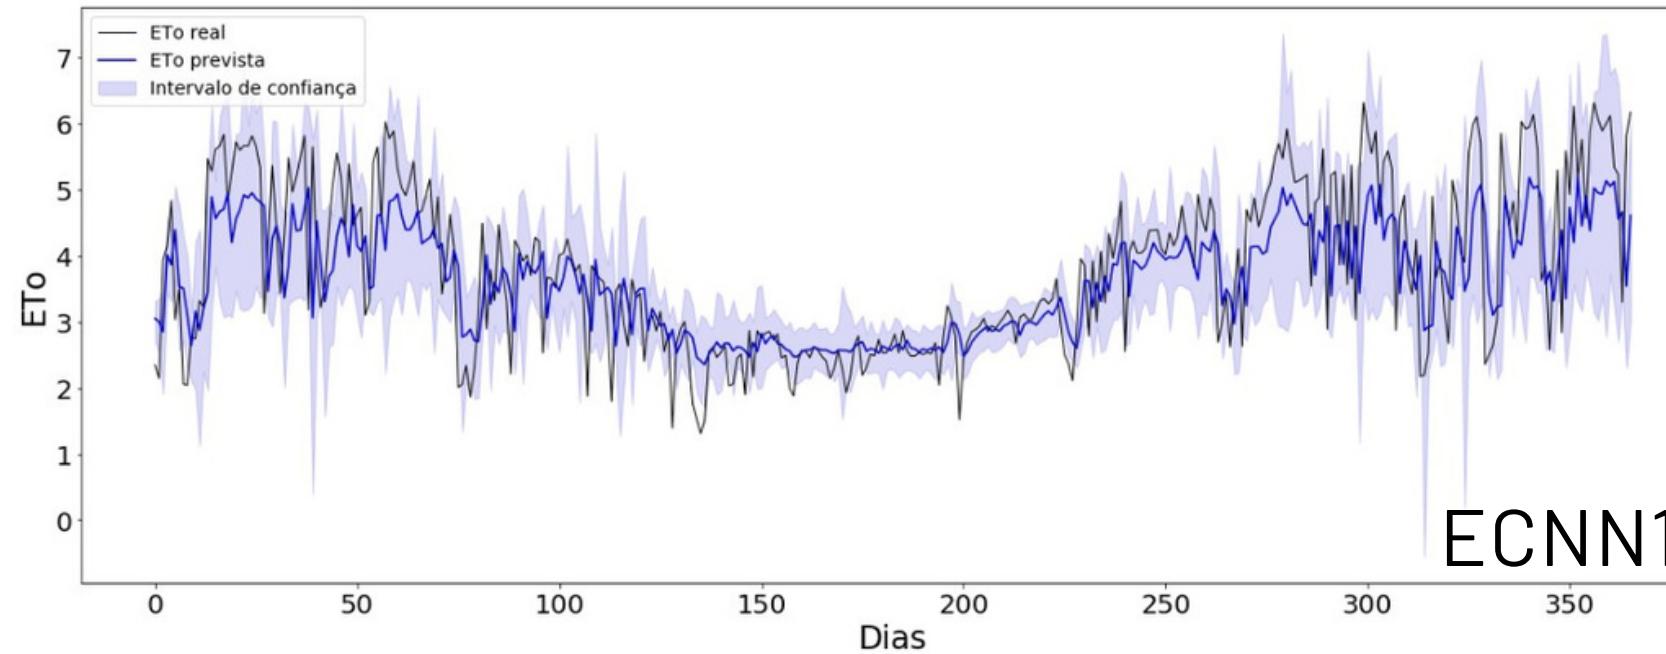
H7



H10

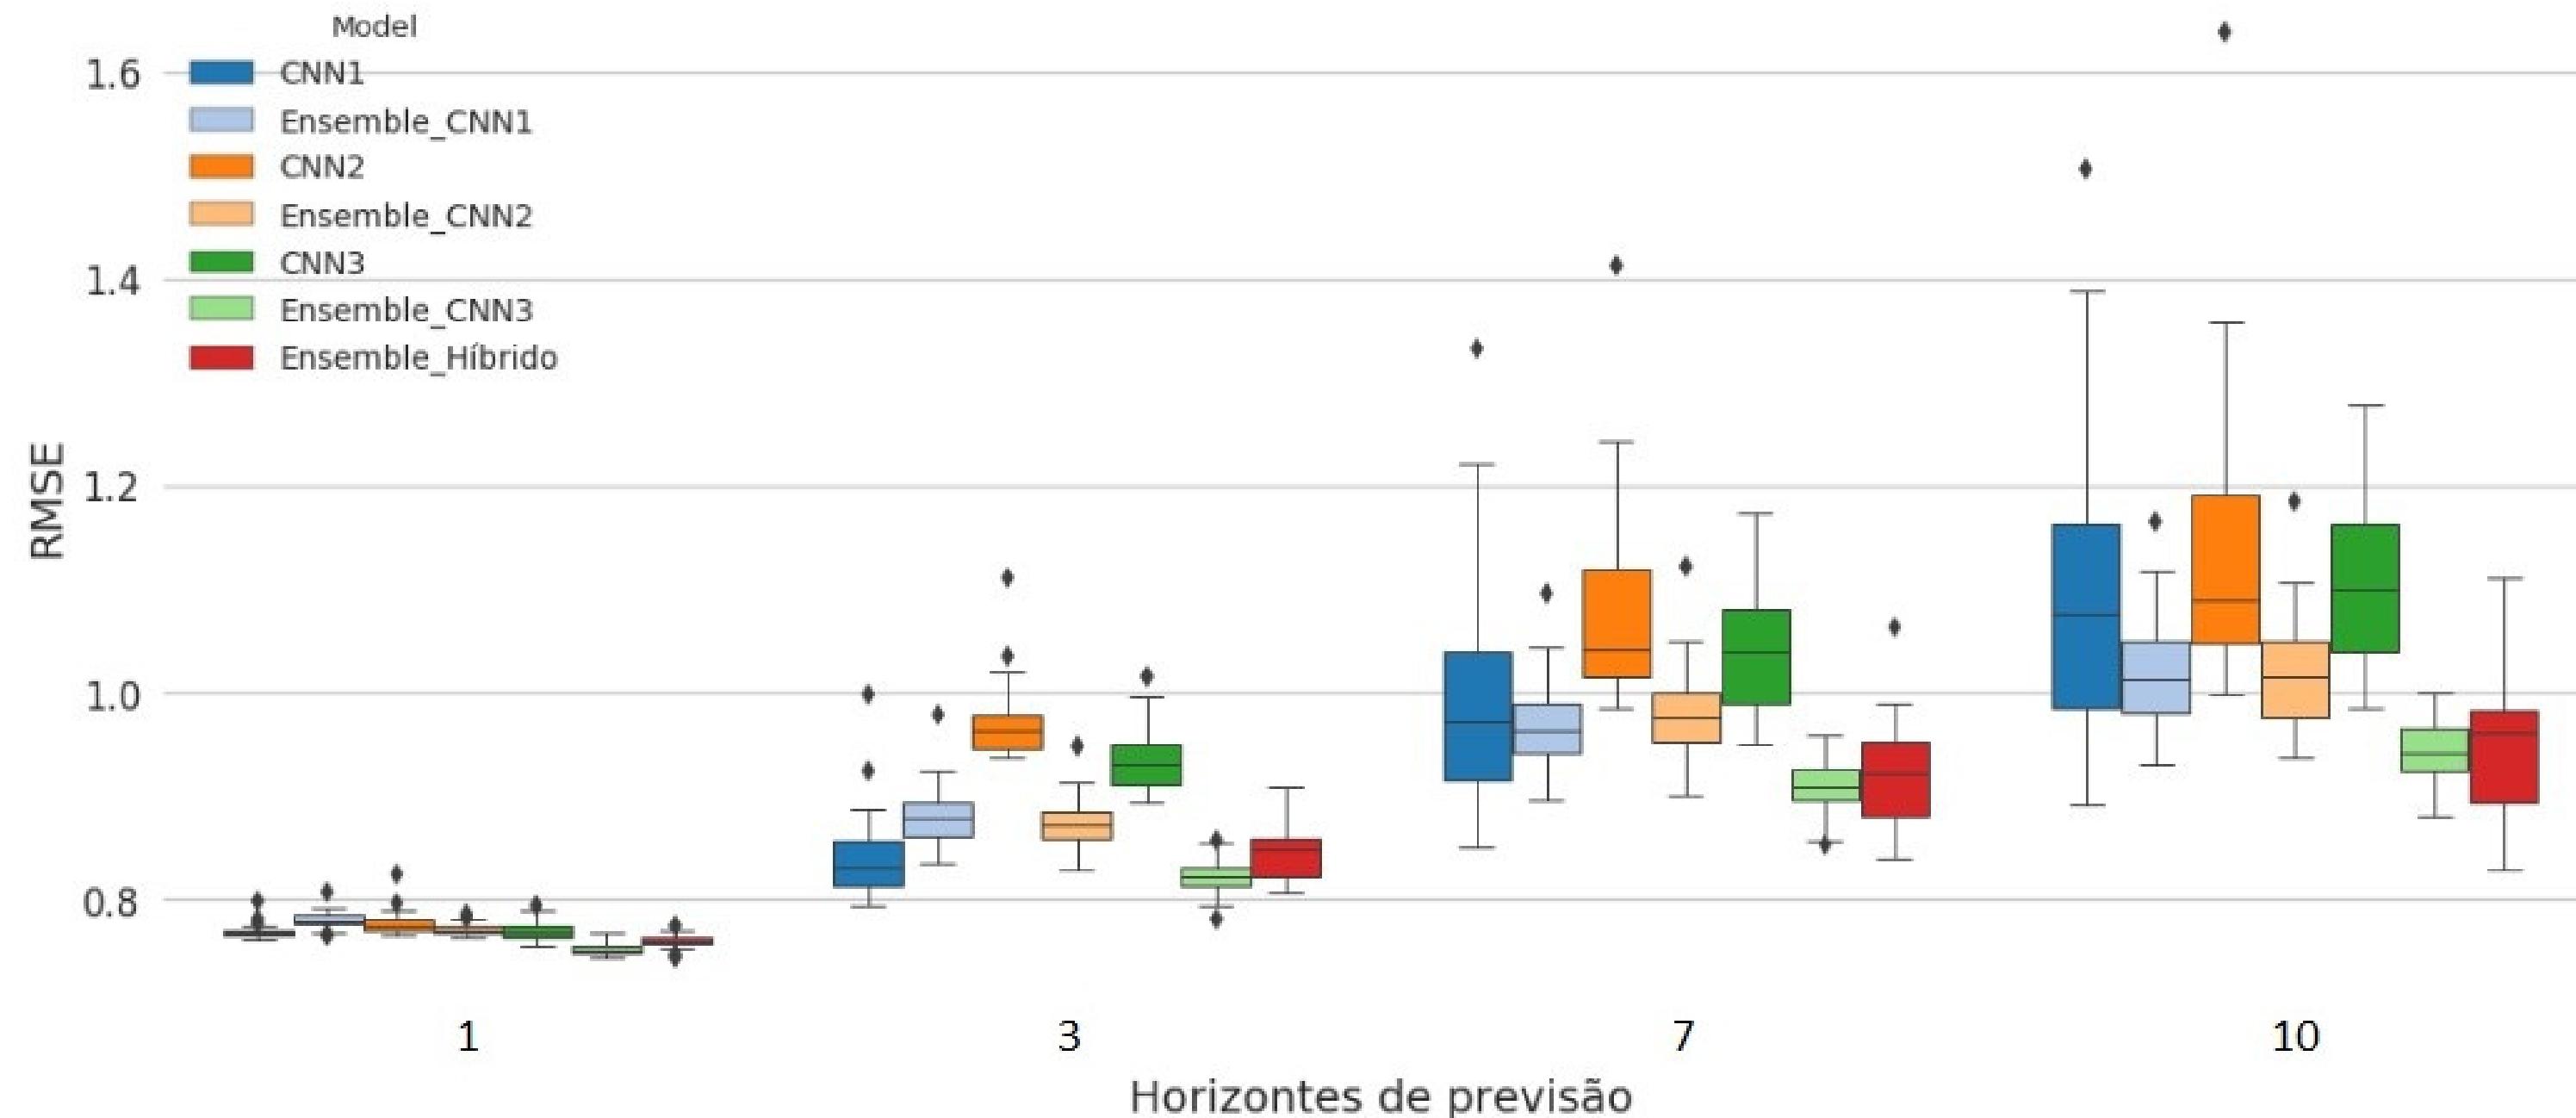
RESULTADOS

Intervalo de confiança - Ensembles (2012)



RESULTADOS

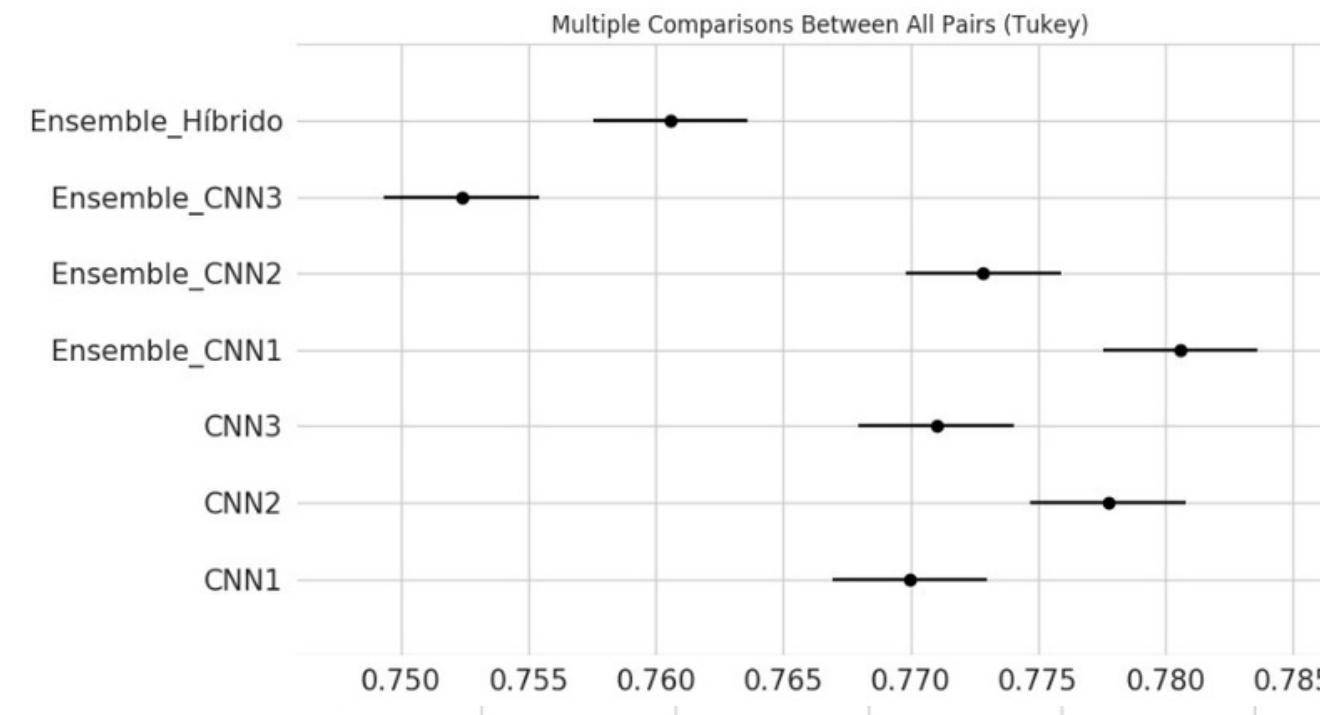
Comparação entre CNNs e ensembles



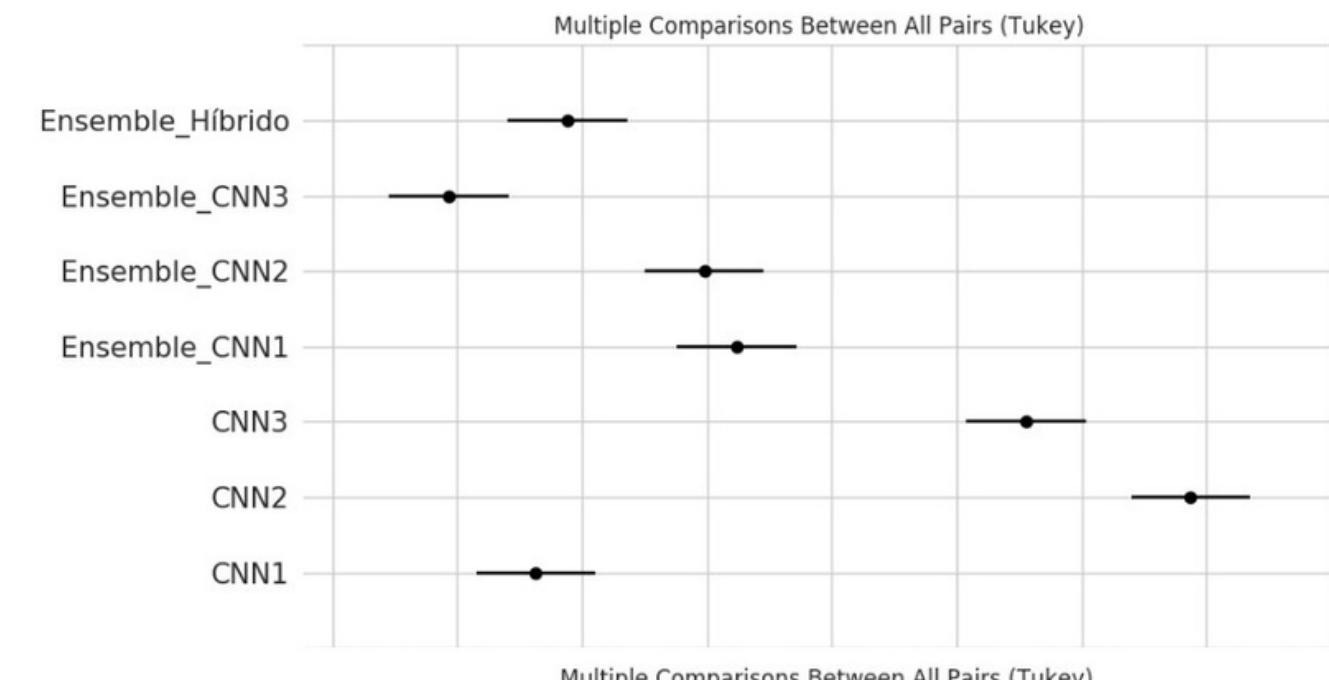
(2015)

RESULTADOS

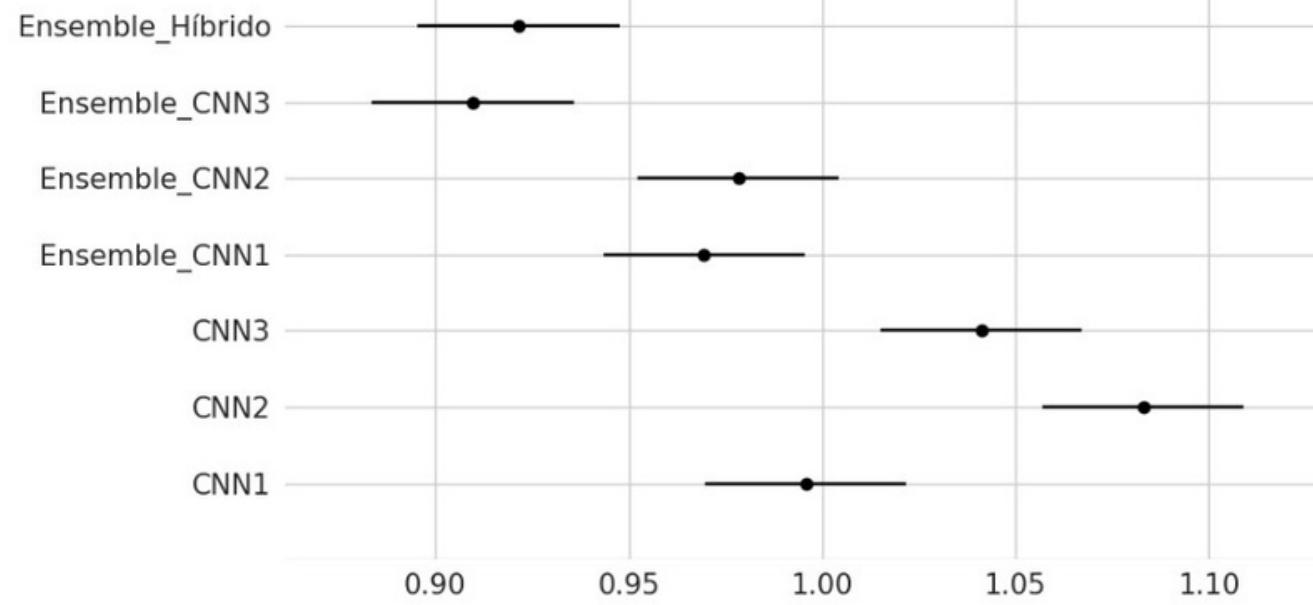
Comparação entre CNNs e ensembles (2015)



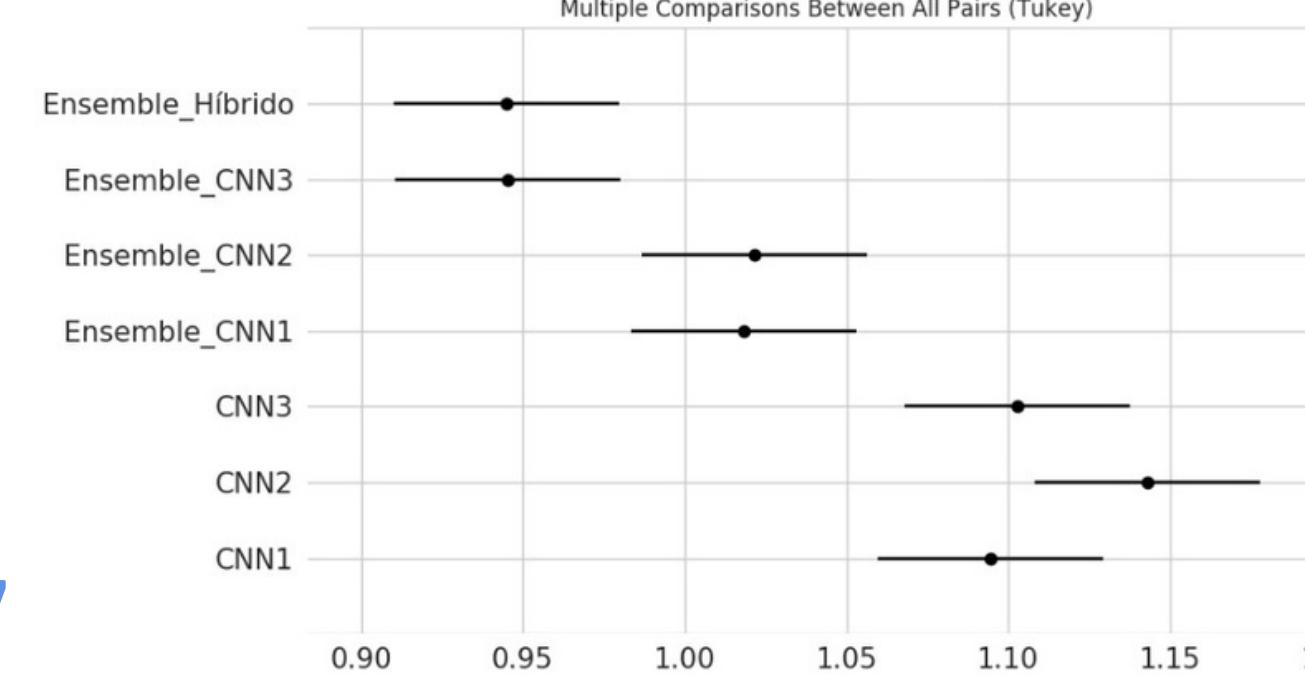
H1



H3



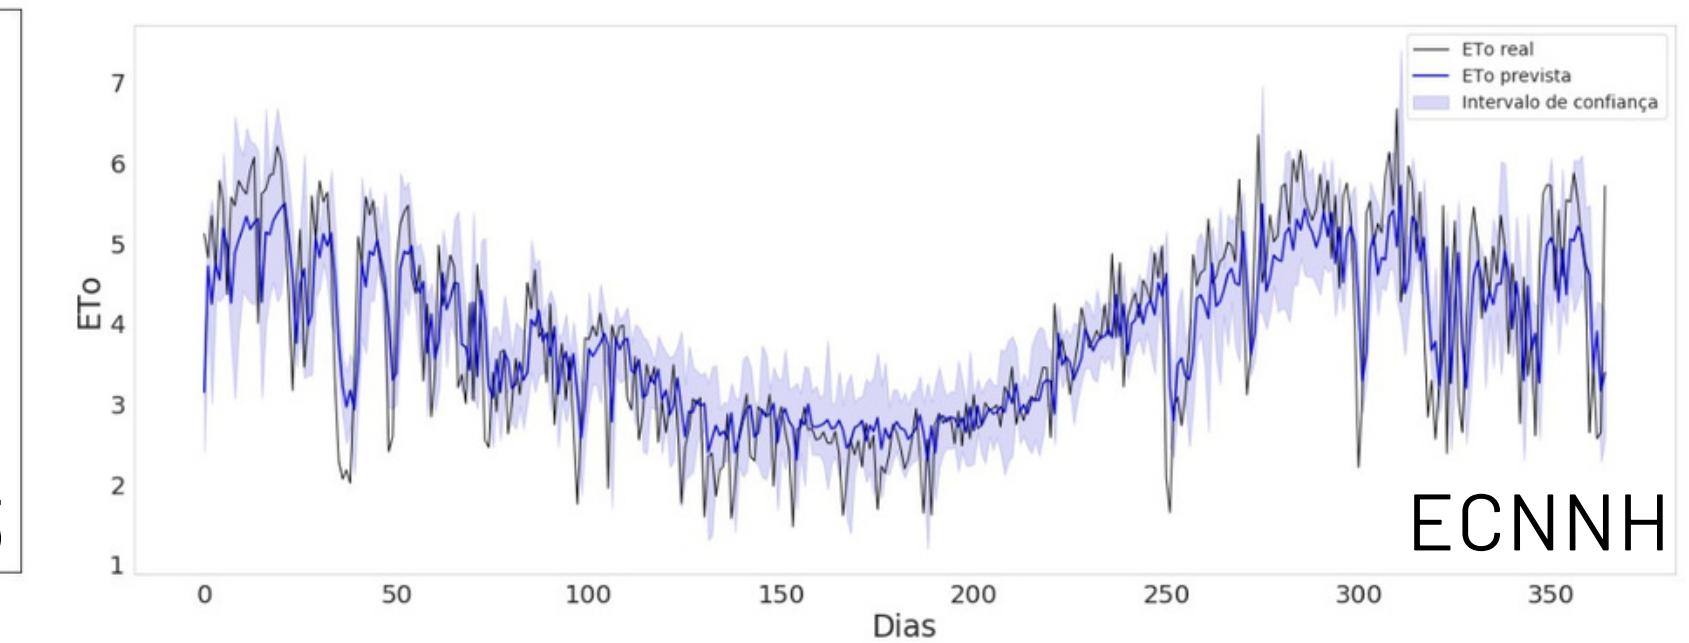
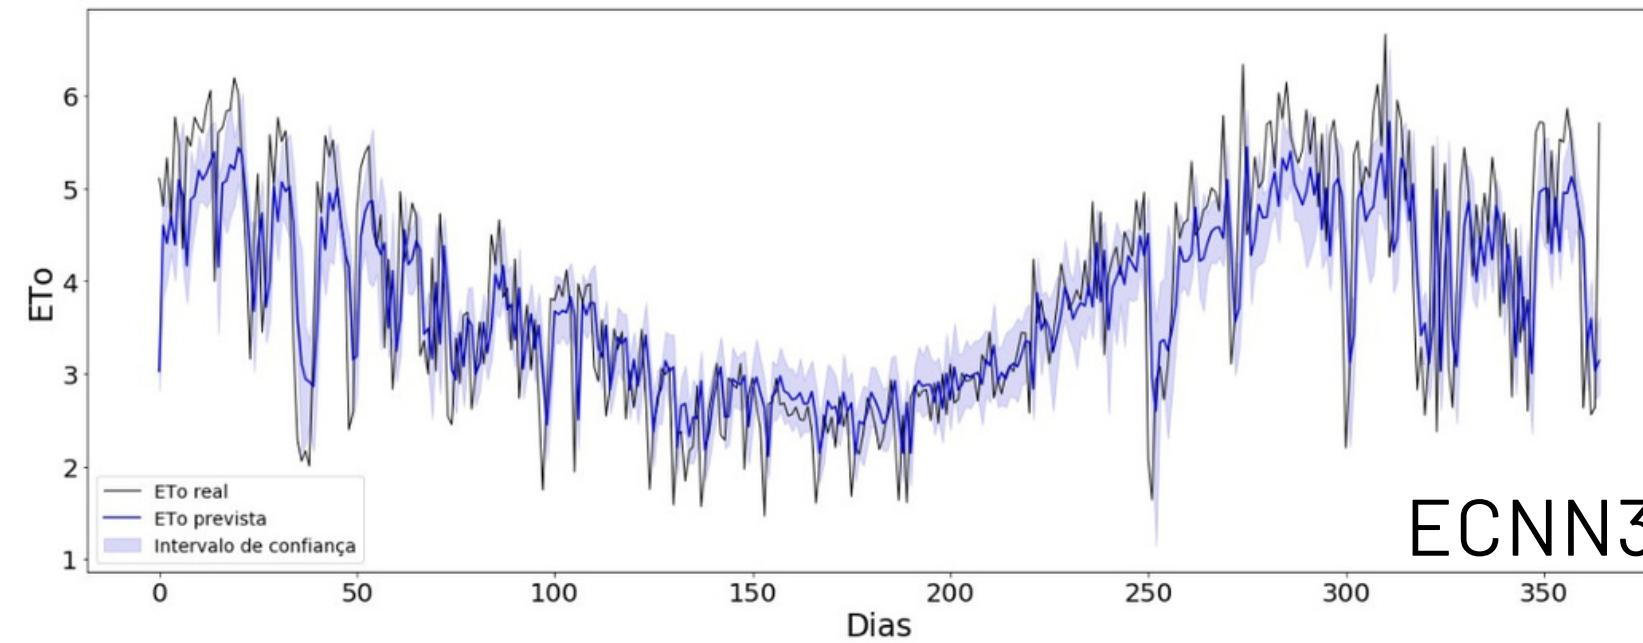
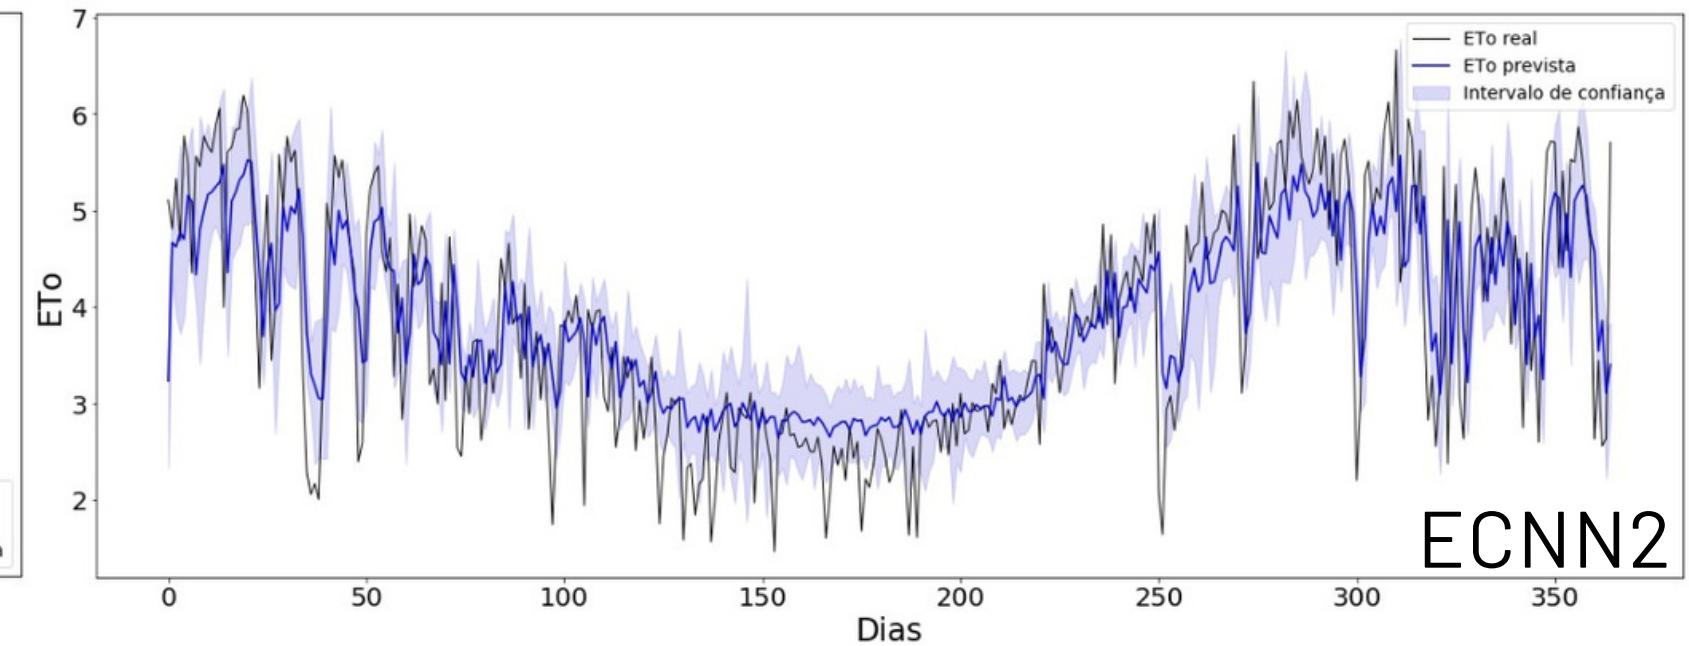
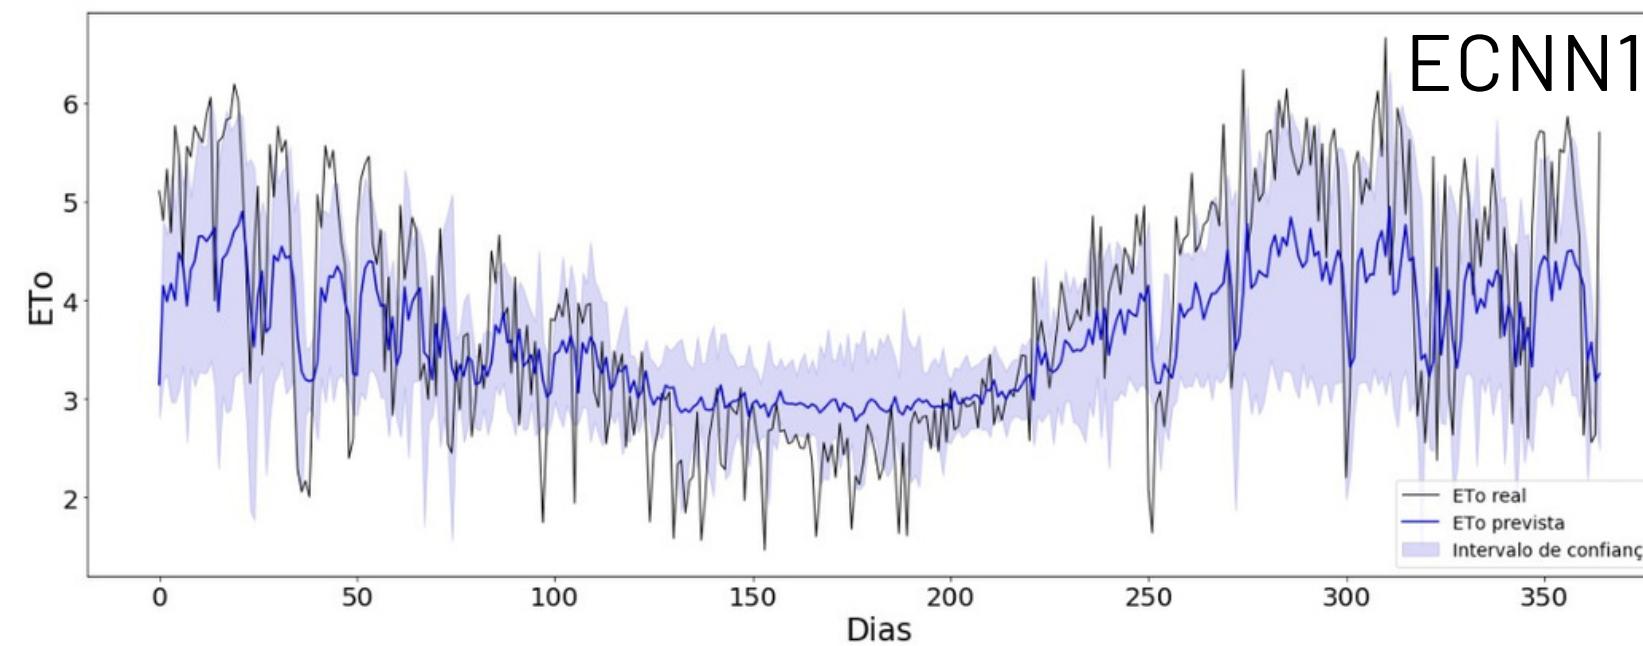
H7



H10

RESULTADOS

Intervalo de confiança - Ensembles (2015)



CONCLUSÃO

- 1 Os resultados mostraram que todos os modelos CNN são viáveis para previsão de séries temporais de ETo e que obtiveram desempenho bem próximos aos modelos ARIMA e WFTS.
- 2 O modelo CNN1 apresentou melhores resultados que os modelos CNN temporais (CNN2 e CNN3) e LSTM.
- 3 Os modelos ensemble (Ensemble CNN1, Ensemble CNN2, Ensemble CNN3 e Ensemble Híbrido) apresentaram de forma geral menor variância que os modelos CNNs individuais.
- 4 Apenas os modelos CNN2 e CNN3, especializados em dados sequenciais, conseguiram diminuir o erro quando trabalharam em conjunto.

CONCLUSÃO

- O desempenho dos modelos ensemble foi satisfatório, visto que os valores da série temporal de
- 5 ETo ficaram dentro dos limites da incerteza desses modelos, sendo o Ensemble CNN3, o modelo que apresentou menor incerteza.
- 6 O método de aprendizagem em conjunto é computacionalmente mais barato e mais simples de desenvolver, pois elimina a etapa de otimização de hiperparâmetros.

TRABALHOS FUTUROS

Utilizar os métodos aqui apresentados para fazer previsões de ETo:

1

- com dados de outras estações meteorológicas com condições climáticas diferentes.
- de forma indireta e comparar com os resultados deste trabalho.
- com uma série temporal multivariada e comparar com os resultados deste trabalho.

2

Utilizar o modelo Ensemble CNN3 para prever séries temporais de ETo multivariadas compostas pelas temperaturas máxima e mínima. Este estudo é interessante para verificar se é possível prever a ETo satisfatoriamente em locais onde não existem estações meteorológicas e que sensores de temperatura simples podem realizar as medições.

TRABALHOS FUTUROS

- Utilizar algum método de clusterização para definir as zonas homogêneas de ETo do norte de
- 3 Minas Gerais com dados das séries temporais de todas as estações meteorológicas localizadas na região.
- 4 Fazer a previsão de ETo de cada zona homogênea utilizando dados das estações meteorológicas que nelas estão localizadas com o modelo Ensemble CNN3.

PUBLICAÇÕES

Patrícia de Oliveira e Lucas; Petrônio Cândido de Lima e Silva; Frederico Gadelha Guimarães. "Otimização Evolutiva e Hiperparâmetros para Modelos de Séries Temporais Nebulosas". 14º Simpósio Brasileiro de Automação Inteligente (SBAI 2019), Ouro Preto, MG. 2019, p. 1-7.

Petrônio Cândido de Lima e Silva; Patrícia de Oliveira e Lucas; Frederico Gadelha Guimarães. "A Distributed Algorithm for Scalable Fuzzy Time Series". 14th International Conference on Green, Pervasive, and Cloud Computing. GPC 2019, Uberlândia. Lecture Notes in Computer Science. 14 ed.: Springer International Publishing, 2019, v.11484, p. 42-56.

OBS: IEEE TNSM (Transactions on Network and Service Management)

AGRADECIMENTOS

- Ao Professor Frederico.
- Aos Professos Petrônio, Eduardo e Rodrigo.
- Aos colegas do MINDS, LACSED e do LITC.
- Ao Instituto Federal do Norte de Minas Gerais - Campus Salinas.